

병원 장비가 달라지면 폐렴 AI는 얼마나 흔들릴까

흉부 X선 3분류 · 장비 차이를 영상처리로 재현해 점검

오형준 · 2026.10.23

PROBLEM · 병원마다 촬영 설정이 다를 수 있다

설정값이 달라지면 사진이 달라진다



관전압 ↑

대비 감소

투과가 쉬워져 사진이 밋밋해진다

관전류 ↓ (선량 ↓)

노이즈 증가

광자가 줄어 알갱이 같은 무늬가 생긴다

노출시간 ↑

움직임 번짐

오래 찍으면 아이가 움직여 번진다

IMPLEMENTED 01 · 기기·촬영 조건 5종 · 약 · 중 · 강

장비 설정 5종을 영상처리로 구현했다

REFERENCE

DEVICE · 기기·촬영 조건 5종 · 증강에 사용



원본

필터를 걸기 전의
정상 흉부 X선

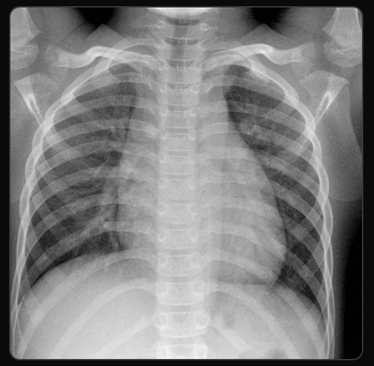
필터 없음



관전압 ↑

대비가 줄고
밝은 곳이 눌린다

×0.85 · 0.70 · 0.60



관전류 ↓ (선량)

광자가 줄어
알갱이 노이즈 증가

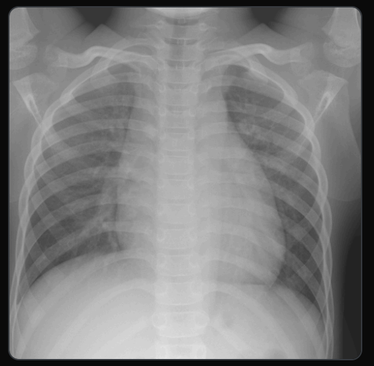
1/4 · 1/16 · 1/64



노출시간 ↑

아이가 움직여
세로로 번진다

번짐 2 · 4 · 8mm



산란 (격자 없음)

산란선이 깔려
안개처럼 흐려진다

k 0.25 · 0.5 · 1.0



센서 해상도

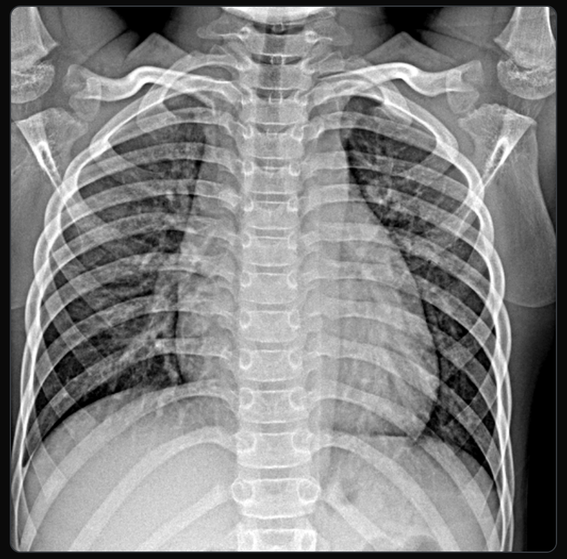
화소가 커져
미세한 무늬 뭉개짐

화소 0.5 · 1.0 · 2.0mm

IMPLEMENTED 02 · 제조사 후처리·전송 3종 · 약 · 중 · 강

후처리와 전송 변화 3종도 구현했다

POST · 제조사 후처리·전송



경계 강조

제조사 후처리: 윤곽을 또렷하게

언샤프 α 0.5 · 1.0 · 2.0



대비 보정

제조사 후처리: 자동 대비 조정

CLAHE 1.5 · 3.0 · HE



JPEG 압축

전송·저장 때 생기는 손실

품질 75 · 40 · 20

NOT IN TRAINING

학습 증강에서는 뺀다

뒤의 장비 효과 증강 학습에는 쓰지 않은 3종

후처리는 실제 알고리즘이 아니라 대표 기법으로 대신함

SETUP · 데이터

한 병원 사진 5,856장을 환자 단위로 나눴다

DATA

5,856장

소아 흉부 X선 · 병원 한 곳(광저우)

정상 · 세균성 · 바이러스성 3분류

PROVIDED VAL

16장

제공된 val은 바이러스성이 0장

평가에 쓸 수 없어 따로 보관만 했다

NEW SPLIT · 환자 단위

학습 train	4,186
검증 val	1,030
평가 test	624

train에서 val을 다시 나눔 (클래스 비율 유지) · test는 제공된 그대로

BASELINE · 기준 모델 B512

기준 모델: val은 높고 test는 낮았다

SETTINGS

모델

ResNet18 (ImageNet 사전학습)

학습 범위

layer4 + 분류층만

입력

512 · 증강·전처리 없음

최적화

Adam · 학습률 0.001 / 0.0001 · 배치 16

에폭

최대 30, val 최고 에폭 선택 (18)

( ) = seed 42의 선택 에폭
학습 3회 = seed 42·43·44

VAL MACRO-F1

0.839

기준 모델 3개 평균 · 1,030장

3개 범위 0.83 ~ 0.84
seed 42 한 개는 0.843

TEST MACRO-F1

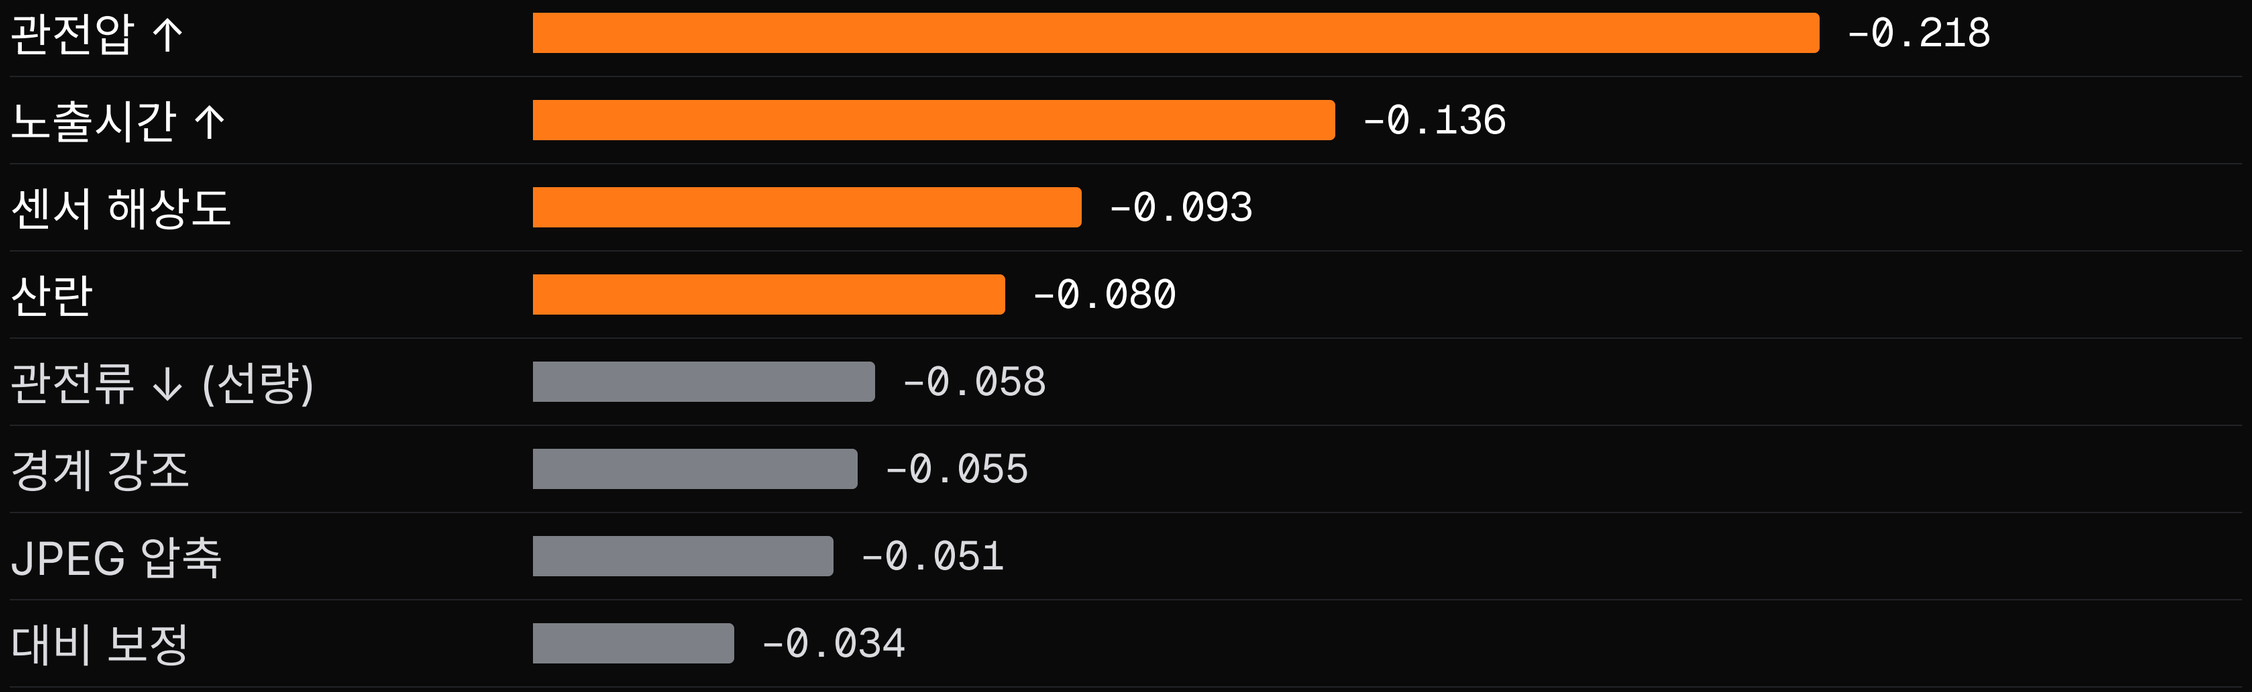
0.705

기준 모델 3개 평균 · 618장

3개 범위 0.67 ~ 0.74 (seed 42는 0.670)
정상 recall 0.45 ~ 0.53

RESULT 01 · 기준 모델에 필터를 걸었을 때 (val 1,030장)

장비 설정 하나로 점수가 최대 0.22 떨어진다

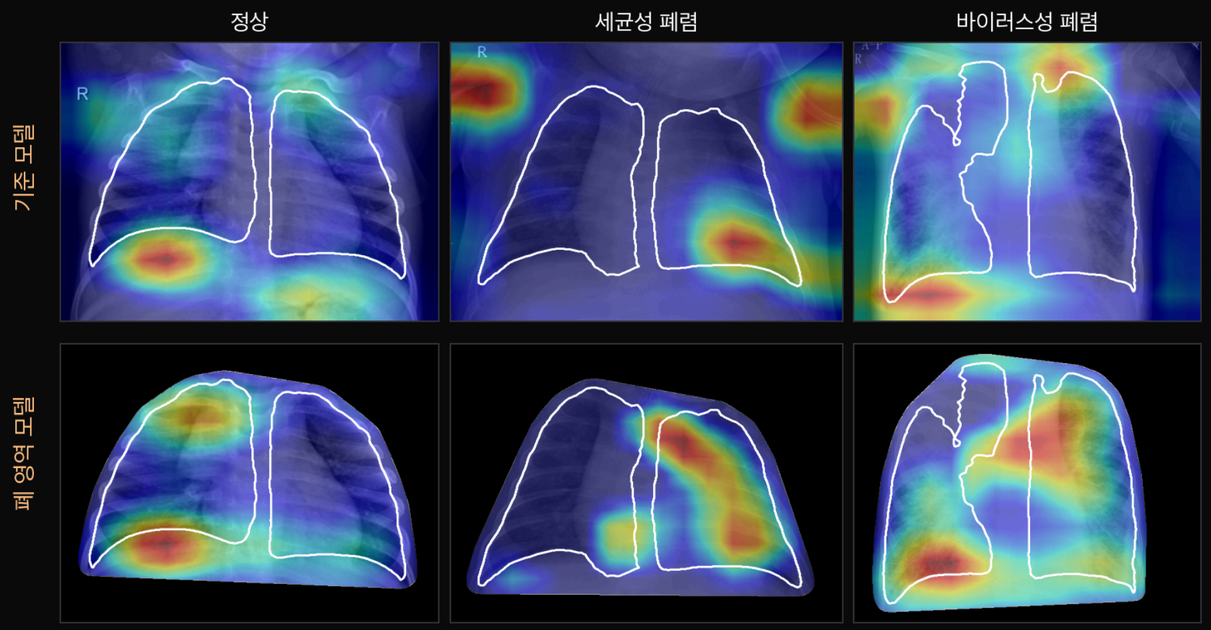


다시 학습한 모델 3개와 새 집단(test)에서도 관전압·노출시간·센서·산란이 크게 떨어졌다

기준 모델 B512 한 번(seed 42) · 원본 Macro-F1 0.843 대비 변화 · 가장 센 단계 · 8개 모두 95% 구간이 0을 포함하지 않음 · 전체 24조건은 백업

CHECK · 모델이 어디를 보는지 확인했다

test가 낮아서 Grad-CAM을 봤다



예시 3장(두 모델이 모두 맞힌 val 사진) · 빨강 = 크게 반응한 곳 · 흰 선 = 폐
Grad-CAM은 어디에 반응했는지만 보여 주고 무엇이 단서인지는 모른다

01

test가 val보다 크게 낮다

val 0.84 → test 0.67 ~ 0.74

02

기준 모델은 폐 밖에 반응

지도 중 폐 안 비율 0.32 (폐 면적 0.36)

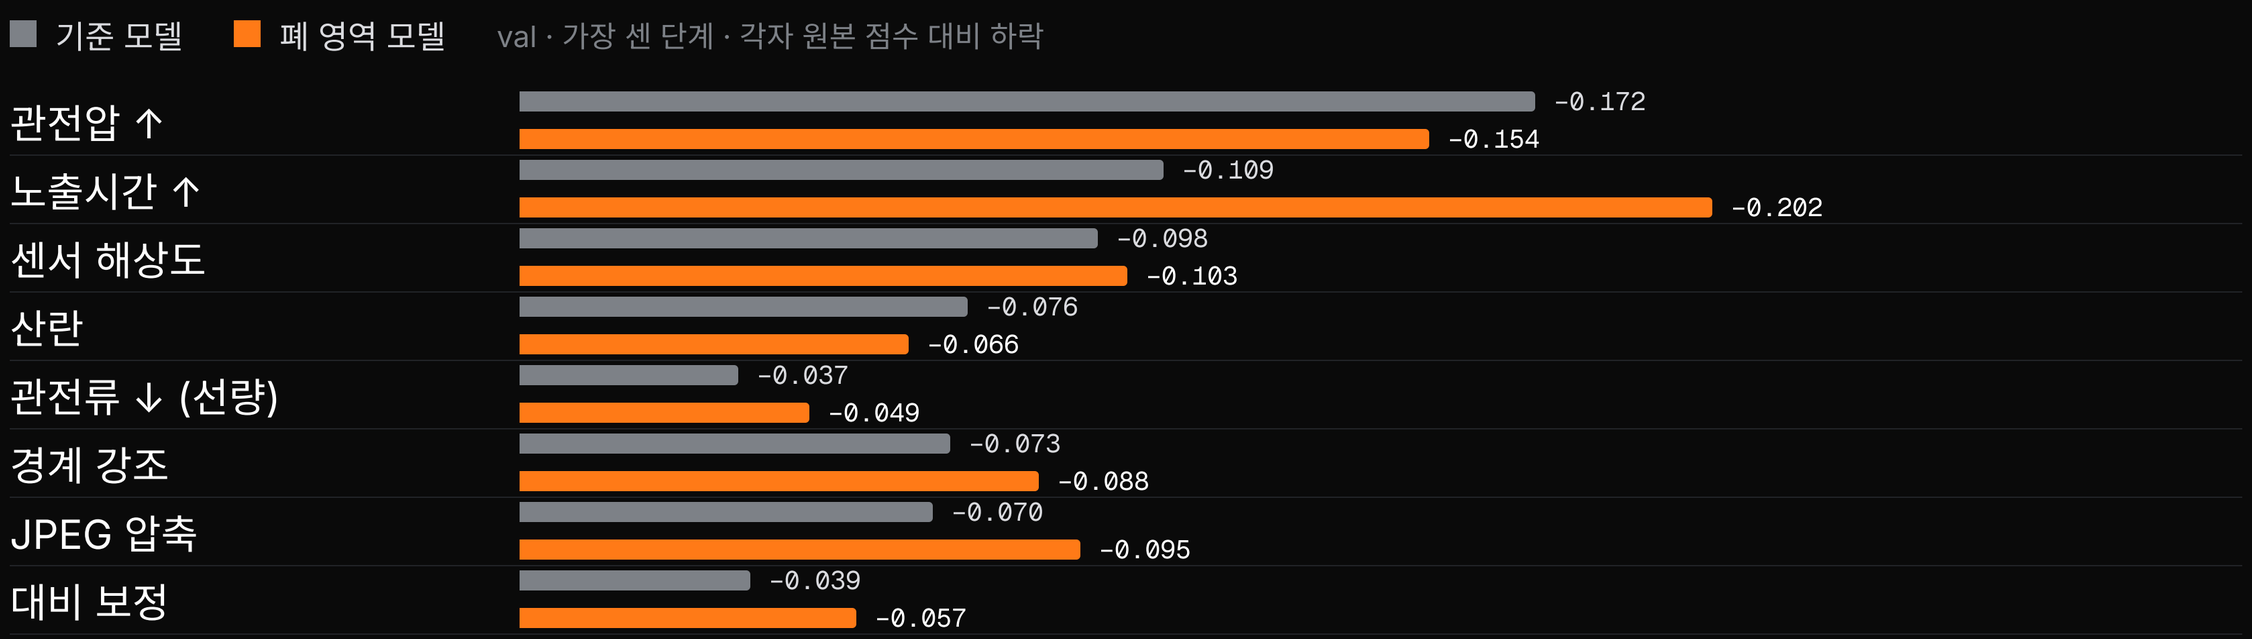
03

폐만 남긴 모델로 재실험

PSPNet으로 폐 밖을 검게 지우고 같은 설정으로 학습 (아래 줄)

RESULT 02 · 폐만 남긴 모델(masked B512)에 같은 필터 (3회 평균)

폐만 남겨도 같은 약점이 남는다



VAL MACRO-F1 · 기준 → 폐

0.839 → 0.826

TEST MACRO-F1 · 기준 → 폐

0.705 → 0.775

24조건 평균 하락 · 기준 → 폐

val −0.044 → −0.054

test −0.066 → −0.070

점수는 3회 학습 평균 · 폐 모델의 test 상승은 '오르는 경향'(val은 약간 낮음) · 필터 약점은 그대로

RESULT 03 · 장비 효과 증강 (증강 전 → 후)

장비 효과를 섞어 학습하면 점수가 올랐다

학습 사진의 절반에 필터 5종(관전압·관전류·노출시간·산란·센서) 중 하나를 무작위 세기로 섞어 학습했다

기준 모델 · 필터를 건 test 사진 평균 점수

0.580 → 0.700

차이 있음 val도 0.774 → 0.815

폐 모델 · 같은 점수

0.660 → 0.721

말할 수 없음

방향은 같지만 학습 때마다 흔들리는 폭 안쪽이다 (val 0.768 → 0.796)

필터를 안 건 평소 사진 점수는 거의 같았다 (평소 성능은 유지)

필터 5종 × 약·중·강 15조건 평균 Macro-F1 · 같은 환경의 모델끼리 비교(각 3회) · 증강 전 모델 3개 흔들림의 2배 이상일 때만 '차이 있음'
시험에 쓴 필터는 학습에 섞은 필터와 같은 종류이므로 실제 장비에 강해졌다는 증거는 아니다

DEPLOY · 기준 모델을 AWS에 올렸다

사진 한 장 → 예측 확률 3개

BROWSER
사진 업로드
JPEG·PNG 한 장
2 MiB 이하

→

EC2
Flask 화면
t3.small · 포트 8000
내 IP에서만 접속

→

LAMBDA
중계
Python 3.12
화면과 모델을 연결

→

SAGEMAKER ENDPOINT
기준 모델 B512
ml.m5.large(CPU)
seed 42 · 18에폭

→

OUTPUT
확률 3개
정상 · 세균성 · 바이러스성
(합 100%)

검산 · ENDPOINT 대 내 컴퓨터

20/20

val 사진 20장의 예측이 모두 같다

확률 최대 차이 0.0000075

전체 경로 시험

1.1초

화면에서 올린 val 1장 → 세균성 0.9998

내 컴퓨터의 같은 모델도 0.9998

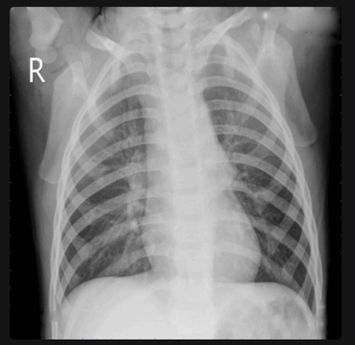
알아 둘 점

확률은 질병 가능성으로 보정된 값이 아니고 진단을 대신하지 않는다

Endpoint는 켜 두는 동안 비용이 나가므로 발표 후 삭제한다

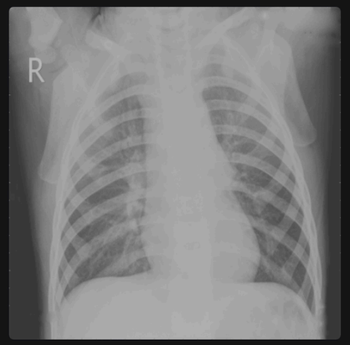
DEMO · 배포한 화면의 필터 체험

필터를 걸면 확률이 바로 바뀐다



원본 → 예측: 정상

정상	**97.5%**
세균성 폐렴	0.0%
바이러스성 폐렴	2.5%



관전압 ↑ (kVp) · 강 → 예측: 바이러스성 폐렴

정상	0.0%
세균성 폐렴	0.0%
바이러스성 폐렴	**100.0%**

예측이 바뀌었습니다: 정상 → 바이러스성 폐렴 (정답: 정상). 정상 확률 97.5% → 0.0% (−97.5%p). 사진 한 장의 결과입니다.

장비에서 일어나는 일

관전압을 높이면 X선이 몸을 더 잘 통과해서 조직 사이의 차이가 줄고 사진이 밋밋해집니다. 뼈처럼 밝은 부위도 덜 하얘집니다.

정상 예시 1장 · 필터 8종(강)의 정상 확률

원본	97.5%	
관전압 ↑	0.0%	→ 바이러스성
센서 해상도	0.0%	→ 바이러스성
산란	0.0%	→ 바이러스성
JPEG 압축	1.2%	→ 바이러스성
노출시간 ↑	65.5%	
관전류 ↓ (선량)	92.1%	
경계 강조	100%	
대비 보정	100%	

왼쪽 = 배포한 화면의 실제 캡처 (예시 3장 또는 업로드 · 필터 8종 · 강도 4단계) · 오른쪽 = 같은 화면에서 정상 예시 1장에 필터를 가장 센 단계로 건 결과
사진 한 장의 결과이고, 평균으로는 val 1,030장에서 관전압 강일 때 정상 recall이 0.985 → 0.406

SUMMARY · 정리

원본 점수만으로는 장비 변화를 알 수 없다

01 기본 모델은 장비 효과에 크게 약했다 (최대 −0.22)

02 폐만 남겨도 같은 약점이 남았다

03 장비 효과 증강으로 필터를 건 점수가 올랐다 (기준 모델)

다음 → 다른 병원의 실제 장비 사진으로 확인

한계: 필터는 실제 장비의 흉내 · 후처리는 대표 기법 · 학습 3회씩 · 폐 영역은 두 단계 시스템 · test 점수가 낮은 원인은 확인 못 함

백업 · 가장 센 단계에서 예측이 어떻게 바뀌나 (기준 모델 하나, val)

틀리는 방식도 장비마다 다르다

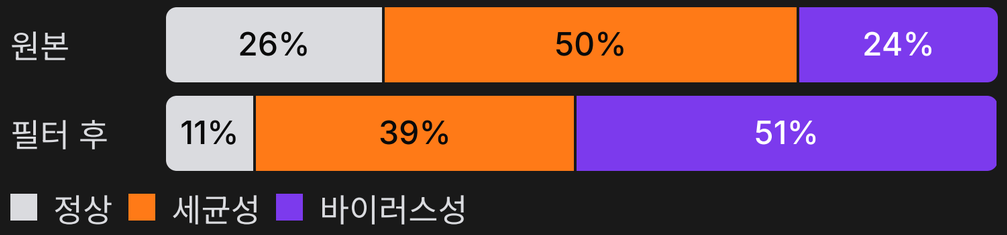
관전압 ↑ · 대비 감소 (가장 센 단계)

정상을 맞힌 비율 (recall)

0.985 → 0.406

정상 사진 10장 중 6장 가까이를 폐렴으로 판정

예측한 클래스의 비율



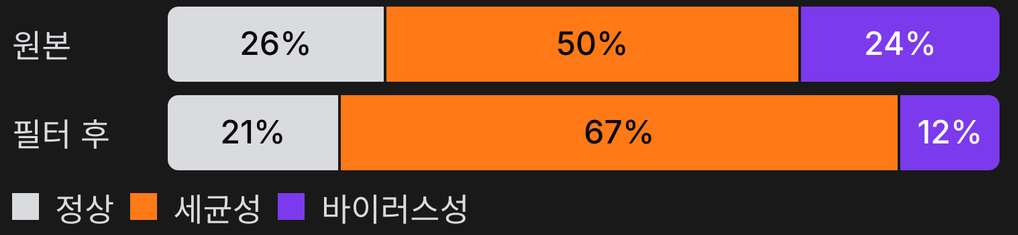
노출시간 ↑ · 움직임 번짐 8mm (가장 센 단계)

바이러스성을 맞힌 비율 (recall)

0.667 → 0.330

바이러스성 폐렴을 세균성으로 판정한 비율 32% → 67%

예측한 클래스의 비율



백업 · 기준 모델 하나(B512, seed 42)의 test 618장 확인

처음 보는 test 사진에서도 같은 약점이 나타났다

원본 test Macro-F1	노출시간 8mm	관전압 ↑ 강	센서 해상도 2.0mm
0.670	−0.228	−0.218	−0.167
95% 구간 [0.624, 0.711]	원본 대비 Macro-F1 변화	원본 대비 Macro-F1 변화	원본 대비 Macro-F1 변화
val은 0.843	val은 −0.136	val은 −0.218	val은 −0.093

val에서 약했던 조건이 test에서도 크게 떨어졌다 (24조건 순위 상관 0.79, 가장 크게 떨어진 6개 중 5개가 같음).

다만 test는 원본 점수부터 낮다: 정상 231장 중 103장만 정상으로 판정(recall 0.446), 폐렴을 정상으로 본 오류는 1건.

test는 계획을 고정한 뒤 한 번만 평가했다 (624장 중 같은 사진의 사본 6장을 뺀 618장). test 정상 사진은 저장 화질·가로세로 비율이 train·val과 다르다(원인으로 단정하지 않음).

필터 8종: 장치 원리와 강도

필터	장치 원리	강도 (약 · 중 · 강)
선량 (mAs)	선량이 줄면 광자가 줄어 양자 노이즈가 늘어난다	상대 선량 1/4 · 1/16 · 1/64
노출시간	오래 찍으면 아이가 움직여 세로로 번진다	번짐 길이 2 · 4 · 8mm
산란 (격자 없음)	산란선이 안개처럼 깔려 작은 구조의 대비가 줄어든다	산란/직접선 비 k 0.25 · 0.5 · 1.0
관전압 kVp ↑	대비가 줄고 밝은 부위(뼈)가 덜 하얘진다	대비 0.85 · 0.70 · 0.60, 밝은 쪽 기울기 0.8 · 0.6 · 0.5
센서 화소 크기	화소가 커지면 미세한 무늬가 뭉개진다	화소 0.5 · 1.0 · 2.0mm
경계 강조	제조사 후처리: 윤곽을 또렷하게 (대표 기법으로 대신)	언샤프 마스킹 α 0.5 · 1.0 · 2.0
대비 보정	제조사 후처리: 자동 대비 조정 (대표 기법으로 대신)	CLAHE 1.5 · CLAHE 3.0 · HE
JPEG 압축	전송·재저장 때 생기는 손실	품질 75 · 40 · 20

구현: 선량은 밝기에 비례하는 노이즈를 더함 · 노출시간은 세로 번짐(아래쪽일수록 큼) · 산란은 원본 + k × 크게 흐린 사진 · kVp는 대비 축소 + 밝은 쪽 눌러 주기 · 센서는 화소 평균 후 다시 키움. 512 사진에서 1mm = 2.29픽셀(224 사진에서 1픽셀 ≈ 1mm 기준). 선량의 기준 노이즈는 원본 노이즈 추정 0.699를 보정한 0.622.

24조건 전체 결과 (B512, val)

필터	약	중	강
관전압 ↑	−0.031 [−0.048, −0.014]*	−0.111 [−0.139, −0.084]*	−0.218 [−0.252, −0.186]*
노출시간	−0.012 [−0.025, +0.002]	−0.051 [−0.070, −0.032]*	−0.136 [−0.165, −0.110]*
센서 해상도	−0.001 [−0.013, +0.010]	−0.027 [−0.045, −0.010]*	−0.093 [−0.121, −0.066]*
산란	−0.016 [−0.030, −0.003]*	−0.031 [−0.052, −0.012]*	−0.080 [−0.106, −0.055]*
대비 보정	−0.015 [−0.032, +0.002]	−0.062 [−0.086, −0.037]*	−0.034 [−0.053, −0.014]*
선량 ↓	+0.006 [−0.003, +0.016]	−0.013 [−0.028, +0.002]	−0.058 [−0.081, −0.038]*
경계 강조	−0.003 [−0.015, +0.011]	−0.008 [−0.023, +0.007]	−0.055 [−0.078, −0.035]*
JPEG 압축	−0.015 [−0.030, −0.001]*	−0.032 [−0.050, −0.015]*	−0.051 [−0.072, −0.031]*

원본 val Macro-F1 0.843 대비 변화 [95% 구간], 환자 묶음 단위 bootstrap 1,000번. * = 구간이 0을 포함하지 않음 (17/24). 강도는 B3 참고.

test 618장: 혼동행렬과 val·test 변화량

정답 ↓ 예측 →	정상	세균성	바이러스성
정상	103	38	90
세균성	1	233	6
바이러스성	0	51	96

test 원본 성능 (618장)

Macro-F1 0.670 [0.624, 0.711] · AUROC 0.906

정상 231장 중 103장만 정상, 폐렴을 정상으로 본 오류 1건

경계 강조 약·중은 test에서 오히려 +0.033 / +0.030 (정상 recall 0.515 / 0.541). 원인은 모른다.

필터	약 val/test	중 val/test	강 val/test
관전압 ↑	−0.031/−0.065	−0.111/−0.162	−0.218/−0.218
노출시간	−0.012/−0.076	−0.051/−0.159	−0.136/−0.228
센서 해상도	−0.001/+0.022	−0.027/−0.028	−0.093/−0.167
산란	−0.016/−0.024	−0.031/−0.043	−0.080/−0.102
대비 보정	−0.015/−0.046	−0.062/−0.131	−0.034/−0.055
선량 ↓	+0.006/−0.012	−0.013/−0.003	−0.058/−0.046
경계 강조	−0.003/+0.033	−0.008/+0.030	−0.055/+0.004
JPEG 압축	−0.015/−0.003	−0.032/−0.022	−0.051/−0.091

원본 대비 Macro-F1 변화 (val 1,030장 / test 618장). 원본은 val 0.843, test 0.670. 필터끼리 강도가 보정되지 않아 필터 사이 직접 비교는 하지 않는다.

백업 · 본편에서 뺀 필터

제외한 3종: 흐림 · 밝게 · 어둡게

필터 (v1)	약	중	강	강 Macro-F1	강 정상 recall
흐림 (σ 0.5 · 1.0 · 2.0)	−0.028*	−0.076*	−0.463*	0.380	0.060
밝게 (감마 0.85 · 0.7 · 0.55)	−0.003	−0.007	−0.022*	0.821	0.955
어둡게 (감마 1.2 · 1.45 · 1.8)	−0.001	+0.001	−0.008	0.835	0.989

본편에서 뺀 이유

처음에 일반 전처리로 정한 필터라 장비 원인과 연결이 약하다. 흐림의 원인은 노출시간·센서가 이미 다룬다.

결과는 지우지 않았다. 흐림 강은 0.380(변화 −0.463)로 가장 크게 떨어졌고, 정상 recall이 0.060까지 내려갔다.

원본 val Macro-F1 0.843 대비 변화, * = 95% 구간이 0을 포함하지 않음. test에서도 33조건 전부 평가하고 보고한다.

백업 · 입력 크기

왜 512인가

클래스	짧은 변 중앙값(px)	1024 미만	512 미만
정상	1,323	11%	0.1%
세균성	752	84%	6.8%
바이러스성	824	74%	6.4%

원본 사진 5,856장의 클래스별 크기. 1024로 맞추면 폐렴 사진 대부분이 확대된다.

224에서는 효과가 가려진다

센서 화소 중간 단계(224 모델 0.9mm, 512 모델 1.0mm)의 원본 대비 변화

+0.001 → −0.027*

B224와 B512는 서로 다른 모델(seed 1개씩)이라 해상도만의 효과는 아니다.

1024는 늘린 정도(선명도)가 클래스 단서가 될 위험이 있어 512를 골랐다. 실제로 모델이 그렇게 쓰는지는 점검하지 않았다.

데이터 분할과 test 분포 차이

분할	정상	세균성	바이러스성	합계
train	1,075	2,042	1,069	4,186
val	266	488	276	1,030
test	231	240	147	618

환자(번호) 묶음 단위·클래스 층화 분할, seed 42. test는 624장에서 같은 사진의 사본 6장을 뺀 618장.

test 정상 사진은 train·val과 다르다

저장 화질 약 75 vs 96, 가로세로 비율 1.35 vs 1.22. 그래서 test는 절대 점수보다 원본 대비 변화를 중심으로 본다. 이 차이가 점수 하락의 원인이라고 단정하지는 않는다.

한계 전체와 용어

- 8비트 JPEG라 실제 톤 곡선과 원본 신호를 모른다 (표시 값이 노출량과 선형이라고 가정)
- 선량의 기준 노이즈는 원본 노이즈 추정에 맞춘 값이다 (순수한 양자 노이즈가 아님)
- kVp는 뼈·연부조직의 에너지별 대비를 못 만들어 대비 감소 + 밝은 쪽 눌러 주기로 근사했다
- 노출시간 번짐 길이와 산란 비율은 실측이 아니라 설정이다 (이동 속도 등은 문헌으로 확인 안 함)
- 센서 화소는 입력 1픽셀(약 0.44mm)보다 작은 값은 만들 수 없다
- 512에서도 사진의 5%는 짧은 변이 512 미만이라 확대된다. 입력 크기가 클래스 단서인지는 확인하지 않았다
- 모델 1개, 학습 1회(seed 1개): 변화가 의미 있는지는 구간과 seed 흔들림을 함께 봐야 한다
- 제조사 후처리(경계 강조, CLAHE/HE)는 실제 알고리즘이 아니라 대표 기법으로 대신한 것이다

용어

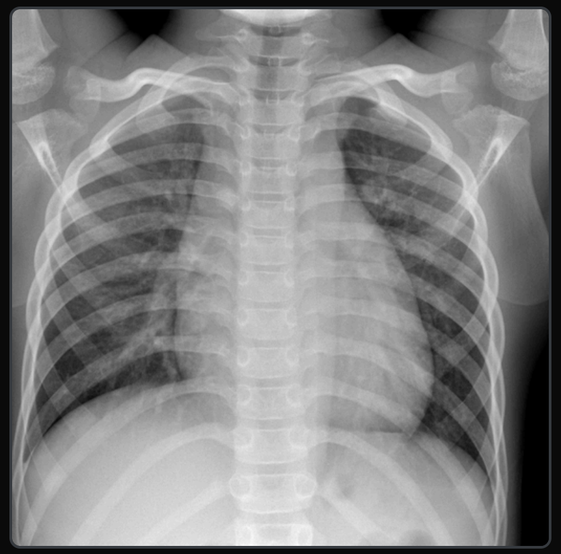
Macro-F1
정상·세균성·바이러스성 세 클래스의 F1을 같은 비중으로 평균한 점수

recall
그 클래스 사진 중 모델이 맞힌 비율

95% 구간
같은 환자 묶음을 다시 뽑아 1,000번 계산한 변화의 범위. 0을 포함하면 차이를 말할 수 없다

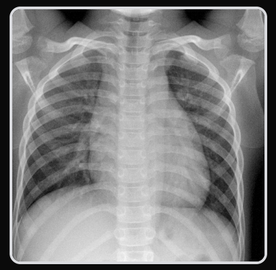
백업 · 필터 8종 × 3단계(약·중·강) · 사진은 가장 센 단계

필터 8종을 같은 사진에 걸어 본 모습



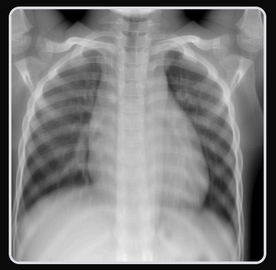
원본

정상 흉부 X선 한 장. 오른쪽 8장은 가장 센 단계



선량 ↓

노이즈 증가



노출시간 ↑

움직임 번짐



산란 (격자 없음)

안개처럼 흐려짐



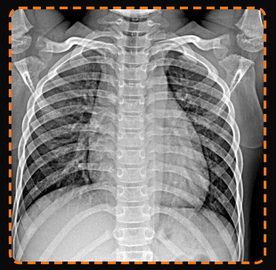
관전압 ↑

대비 감소



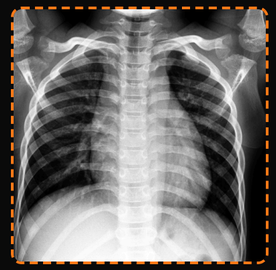
센서 화소 ↑

해상도 저하



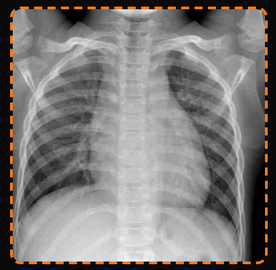
경계 강조

윤곽을 또렷하게



대비 보정

대비 자동 조정



JPEG 압축

압축 흔적

■ 기기 설정 5종 (뒤에서 학습에도 섞어 봄) ⬚ 제조사 후처리 · 전송 3종 (학습에는 안 씀 = 처음 보는 유형 · 후처리는 대표 기법으로 대신함)

폐 영역 모델: 만드는 법, 실패, 점수

만드는 법

PSPNet(TorchXRayVision)이 왼쪽·오른쪽 폐를 칠한다

폐 마스크의 볼록 껍질 + 16px(약 3%) 밖은 검게 지운다 (자르기·확대 없음)

필터는 먼저 걸고 같은 고정 마스크를 씌운다 · 나머지 설정은 기준과 같다

실패와 한계

폐 면적 5% 미만이면 전체 사진을 쓴다: 학습 4장 · val 1장, 전부 세균성(폐가 하얗게 찬 사진)

마스크가 쪼개진 사진: 세균성 2.7% · 바이러스성 1.3% · 정상 0%

분할 오류가 그대로 전달되는 두 단계 시스템

점수 (3회 평균, 기준 → 폐 모델)

val 원본 F1	0.839 → 0.826
test 원본 F1	0.705 → 0.775
test 정상 recall	0.483 → 0.605

test는 기준 흔들림의 2.1배(F1)·2.7배(정상 recall)로 '차이 있음'의 문턱 근처, val은 말할 수 없음. 다른 환경 기준(JupyterLab)과는 1.5배라 규칙에 못 미친다.

점수가 올랐다는 이유로 기준을 바꾸지 않았다 (점수로 모델을 고르는 것이 되기 때문)