See-Through CXR

장비 설정이 만드는 영상 차이에 흉부 X선 폐렴 3분류 모델은 얼마나 흔들리는가

작성자	오형준 (개인 프로젝트) · 보고서 작성 2026.10.26
수행 기간	2026.10.13 (화) ~ 10.23 (금) · 최종 발표 10.23
데이터	Chest X-Ray Images (Pneumonia), Kermany et al. 2018 · 5,856장 · 정상 / 세균성 폐렴 / 바이러스성 폐렴
모델 · 환경	ResNet18 (ImageNet 사전학습) 전이학습, 입력 512×512 · AWS 서울 리전 (S3, SageMaker 학습 작업·Endpoint, Lambda, EC2)
기준 문서	프로젝트 기획안 v0.4 (2026.10.14 제출) · 과정 AWS 프로젝트 가이드 v3
소스코드·데이터	GitHub 저장소 **github.com/MuakTiger/p1-see-through-cxr** (코드, 목록표·분할, 실험별 학습 기록, 보고서·발표자료, 종료 기록)

한 줄 결론. 원본 사진으로 잰 점수(val 0.84, test 0.70)만으로는 장비가 바뀔 때의 성능을 알 수 없다. 장비 설정을 흉내 낸 필터를 걸자 점수가 크게 떨어졌고, 폐만 남긴 모델에서도 같은 약점이 남았다. 기획안과 달라진 점이 많아서 **2장**에 바뀐 내용과 이유, 기획 목표 대비 실측값을 먼저 정리했다.

0.839 / 0.705
기준 모델의 원본 사진 점수, val / test (Macro-F1, 모델 3개 평균)

−0.173
관전압 필터(가장 센 단계)에서 val 점수 변화. test는 −0.231 (모델 3개 평균)

−0.044 / −0.054
필터 24조건 평균 점수 변화(val), 기준 모델 / 폐만 남긴 모델. test는 −0.066 / −0.070

0.580 → 0.700
장비 효과 증강 뒤 test 점수 (학습에 섞은 필터 5종, 기준 모델). 같은 종류 필터라 실제 장비에 강해졌다는 증거는 아님

목차

1 프로젝트 개요 2
2 기획안 대비 변경 사항 2
3 데이터와 분할 4
4 방법 5
5 결과 7
6 점수를 믿을 수 있는가: 진단 11
7 AWS 구성, 검산, 종료 기록 13
8 한계와 다음 단계 14
부록 A 필터 33조건 전체 결과 16
부록 B 초기 실험 (입력 224) 17
부록 C 가이드 필수 제출물 대응표 18
부록 D 모델 S3 주소 18
부록 E 제출 패키지 구성과 재현 방법 19
부록 F 용어 20

1 프로젝트 개요

1.1 배경과 목적

흉부 X선 사진은 병원과 촬영 조건에 따라 밝기·대비·노이즈·선명도가 달라진다. 관전압(kVp), 관전류와 노출시간, 산란선을 줄이는 격자, 검출기 화소 크기, 제조사의 영상 후처리가 모두 영상에 흔적을 남기기 때문이다. 기획안은 한 병원 데이터로 학습한 폐렴 모델이 병원별 장비의 특성이나 영상 위 글자·마커 같은 '지름길'을 배워서 다른 병원에서 성능이 떨어진 사례(Zech et al., 2018)를 문제의식으로 삼았다.

우리가 가진 데이터는 광저우의 한 병원 사진뿐이라 다른 병원 사진으로 직접 확인할 수 없다. 그래서 **같은 사진에 장비 설정이 만드는 효과를 고전 영상처리로 흉내 내어 걸어 보고, 모델의 점수가 얼마나 변하는지 재는 방법**을 택했다. 기획안의 '정확도 숫자만으로는 맞는 이유로 맞혔는지 알 수 없다'는 문제의식을 그대로 이어받아, 설명을 보여 주는 것에서 한 걸음 더 나아가 **모델을 흔들어 보고 확인하는 것**으로 무게를 옮겼다.

1.2 연구 질문

구분	질문	이 보고서의 위치
시험 ①	원본 사진으로 학습한 기준 모델은 장비 효과를 건 사진에서 점수가 얼마나 떨어지는가?	5.2절
시험 ②	점수가 떨어지는 이유가 모델이 폐 밖의 단서를 쓰기 때문인가? 폐 영역만 남겨도 같은가?	5.3절
시험 ③	장비 효과를 섞어서 학습하면 약점이 줄어드는가?	5.4절
점검	test 점수(특히 정상 사진의 recall)를 그대로 믿어도 되는가? 모델은 어디를 보는가?	6장

1.3 이 보고서의 숫자를 읽는 법

- **val은 개발용, test는 마지막 확인용**이다. 필터·강도·모델 설계의 근거는 val 결과와 장비에 대한 사전 지식뿐이고(알고 있던 test 결과는 근거로 쓰지 않았다, 2.4절), test에는 같은 필터를 한 번 걸어 같은 방향인지 확인했다.
- **모델은 설정마다 seed 3개(42·43·44)**로 학습했다. seed는 난수만 바꾸고 데이터 분할은 같다. 점수는 3개의 평균 ± 표준편차로 적고, 두 묶음의 평균 차이가 **기준 묶음 표준편차의 2배 이상**일 때만 '차이 있음'이라 쓴다. 그보다 작으면 '말할 수 없음'이다.
- 학습 환경이 둘이다 (AWS 학습 작업 torch 2.2, SageMaker JupyterLab torch 2.8). 같은 설정이어도 환경이 다르면 점수가 달라질 수 있어서 **비교는 같은 환경의 모델끼리만** 했다.
- 용어는 부록 F에 있다.

2 기획안 대비 변경 사항

기획안(10/14)은 **설명 가능한 폐렴 3분류 서비스**를 목표로 했다. 실제로 한 일은 **'점수를 믿을 수 있는가, 장비가 바뀌면 점수가 얼마나 변하는가'를 시험하는 쪽**으로 옮겨 갔다. 옮겨 간 이유는 첫 test에서 정상 recall이 0.44로 떨어진 일과 강사 의견이고, 방향은 기획안 1.1절의 문제의식(장비 지름길, 숫자만으로는 맞는 이유로 맞혔는지 모른다)과 이어진다. 기획안 1.3절에서 약속한 대로 계획값 옆에 실측값을 나란히 적는다(2.3절).

2.1 무엇이 어떻게 바뀌었나

항목	기획안 (10/14)	최종 결과물	바뀐 이유
중심 주제	블랙박스 없이: Grad-CAM, 폐 영역 집중도(LFR), 확신도 기반 판단 보류, 보호자용 쉬운 설명, 고전 전처리 비교	**장비 설정 차이에 대한 점수 민감도**: 필터 8종 시험, 폐 영역 모델, 장비 효과 증강. Grad-CAM은 점수가 낮은 이유를 진단하는 도구로 유지	10/19 첫 test에서 정상 recall이 val 0.98 → test 0.44로 떨어지고 모델 8개가 모두 같았다. 점수를 믿을 수 있는지가 먼저 답할 질문이 되었고, 기획안의 동기(장비 지름길)를 직접 시험하는 쪽으로 옮겼다
입력 크기	224×224 (가이드의 시작 제안)	**512×512**	강사 의견: 224로 줄이면 필터 효과가 뭉개진다. 224 시험에서 센서 0.9 mm 필터의 점수 변화가 0이었다
기준 모델	검증 점수로 고른 최종 모델 (실제로는 실험 D: 노이즈 증강, 224)	**B512**: 증강·전처리 없이 layer4+fc만 학습, 512, seed 3개	연구 질문이 '기본 모델의 민감도'라서 증강 모델 D를 기준에서 내렸다. D는 노이즈 시험과 같은 종류의 증강이라 '배운 유형으로 본 시험'이 되기도 했다 (2.4 공개 사항 참고)

항목	기획안 (10/14)	최종 결과물	바뀐 이유
전처리 비교 (P 시리즈)	HE · CLAHE · LPF · HPF 전처리 4종을 224에서 비교하고 검증 점수로 최종 전처리 선정	P1~P4 학습·평가는 **완료**(224, 부록 B). 결과: 원본 점수 차이는 흔들림 수준이라 전처리는 원본(P0) 유지. 이 고전 영상처리 아이디어를 **장비 설정을 흉내 내는 필터 8종**으로 확장	전처리마다 장비 차이에 강한 곳·약한 곳이 달랐다 (예: CLAHE는 노이즈에 가장 약했다). 필터를 '학습 전 정리'가 아니라 '시험 조건'으로 쓰는 편이 질문에 맞았다
설명 가능성	Grad-CAM + LFR + 판단 보류 + 근거 문장 + 보호자용 문장 틀, Endpoint가 Grad-CAM·LFR까지 계산	Grad-CAM 구현·점검 완료, 폐 마스크로 '폐 안 비율' 측정(0.32, 폐 면적 비율 0.36). 규칙 기반 설명문은 224 모델 D로 구현했으나 최종 흐름에는 연결하지 않음. **판단 보류 곡선·보호자용 4단 문장 틀·이해도 평가는 하지 않음**	우선순위를 '필수 먼저'로 정리하면서 모델·주제가 바뀌었고 일정(실제 작업일 약 7일)이 부족했다. 배포 모델(Endpoint)도 확률 3개만 돌려준다
폐 마스킹 실험 (E)	선택(Could) 항목	**수행**: PSPNet 폐 마스크로 폐 밖을 지운 모델 3개 (+ 장비 효과 증강 3개)	Grad-CAM이 폐 밖에 반응하는 것을 보고, 필터 때문에 점수가 떨어지는 것이 '폐 밖 단서' 탓인지 확인하려고 승격했다
증강	실험 D: 증강 조건 1개 (회전 또는 밝기)	초기: 노이즈 증강 D (224). 최종: **장비 효과 증강** — 학습 사진의 50%에 장비 필터 5종 중 하나를 무작위 세기로	필터 시험에서 노이즈에 크게 무너진 약점(노이즈 std 16에서 F1 0.363)이 먼저 보여 노이즈 증강을 해 보았고, 이를 장비 설정 5종 전체로 넓혔다
반복·통계	단일 seed 42 (시간이 되면 최종 후보 2개를 seed 3개로)	**모든 모델을 seed 3개**로 학습, '기준 표준편차의 2배' 판정 규칙, 환자 묶음 bootstrap 구간	D를 seed 3개로 다시 학습하자 원본 점수 개선(0.834)이 seed 흔들림(0.818~0.834) 안쪽으로 드러났다. 한 번의 점수로 모델을 비교하면 안 된다는 것을 확인했다
test 사용	최종 후보에 대해 1회	224 모델 8개에 각 1회 (평가 계획 해시 고정), 이후 B512 계열은 **모델마다 사전 계획 문서와 해시를 고정한 뒤 1회**. test 점수를 보고 모델·필터·강도를 바꾸지 않음	test가 이미 열렸으므로 '이미 열린 test에서의 사전 지정 추가 분석'이라고 계획 문서 1장에 밝혔다
AWS 서비스	S3 → 학습 → Endpoint(예측+Grad-CAM+LFR) → EC2 Flask API + Streamlit 화면	S3 → 학습 작업 → **Endpoint(확률 3개)** → **Lambda** → **EC2 Flask 화면 2종**(사진 올리기, 필터 체험). 10/23 배포·검산·발표 시연, **발표 직후 모두 삭제**	강의 실습서 v4의 구조를 따랐다. Grad-CAM·설명문은 로컬 Streamlit 화면(224 모델 D)에서만 구현했다
제출물	시연 영상(MP4), 종료 체크리스트와 콘솔 스크린샷	시연은 **발표 중 실시간**(화면 캡처는 발표자료 12쪽). 시연 영상 파일은 없음. 종료 기록은 **콘솔 스크린샷 대신 CLI 조회 기록**(7.5절)	배포를 발표 당일 오전에 만들었고 발표 직후 지웠다. 영상 파일은 이 제출물에 포함하지 않았다

바뀌지 않은 것: 데이터(Kermany 5,856장)와 3분류, ResNet18 전이학습, Adam·배치 16·최대 30에폭·검증 Macro-F1 최고 에폭 선택, 환자 그룹 단위 분할, test 624장 고정, 기획서의 범위 밖 항목(Bedrock·LLM 설명, 진단 목적 사용 금지).

2.2 바뀐 순서

날짜	한 일	그 결과 · 바뀐 것
10/13~14	기획안 작성·제출(v0.4), 목록표·환자 단위 분할, 데이터 점검	train 4,186 / val 1,030 / 점검용 16 / test 624로 확정
10/16~19	입력 224로 실험 A(몸통 고정)·B(layer4)·C(클래스 가중치)·D(노이즈 증강)와 전처리 P1~P4 학습. val에 필터 8종×3단계를 건 '장비 차이 시험' 첫 시도	B가 노이즈에 크게 무너짐(std 16에서 F1 0.363, 예측이 바이러스성으로 쏠림) → 노이즈 증강 D
10/19	test 1회 평가 (224 모델 8개)	D의 test F1 0.692, **정상 recall 0.442**. 8개 모델 모두 val보다 0.06~0.15 낮고 val 순위가 test 순위를 예측하지 못함
10/20	원인 분석(파일 저장 방식·가로세로 비율·Grad-CAM), 입력 448 실험, 강사 의견 반영	저장 화질은 원인이 아님을 확인. 224에서는 필터 효과가 뭉개진다는 의견 → 512로 이동
10/21	D를 seed 3개로 반복, 분할 점검, Streamlit 시연 화면(D, 로컬)	D의 원본 점수 개선은 seed 흔들림 안쪽. 노이즈 약점 보완만 3개 seed에서 재현
10/22	**주제 전환**: 장비 설정 필터 v2(원리 기반 5종)·512·기준 모델 B512 확정, 필터 강도를 문서로 고정 → val 시험 → test 1회. 폐 영역 모델·장비 효과 증강을 seed 3개씩 학습·평가	필터 시험 ①②③의 결과 확보 (5장)
10/23	AWS 배포(Endpoint → Lambda → EC2), 검산, 최종 발표, 자원 삭제	배포 모델 = 로컬 모델 (예측 20/20 일치). 삭제 후 0개 확인 (7.5절)

2.3 기획안의 성공 기준 대비 실측

기획안 2.1절의 계획값(성공 기준) 7개를 그대로 가져와 실측값을 옆에 적었다. ●는 달성, ◐는 부분 달성, ○는 미달 또는 미실시다.

기획안의 성공 기준 (계획값)	실측	판정
Q1 테스트 Macro-F1 ≥ 0.75	기준 모델 **0.705** ± 0.033 (0.670 / 0.736 / 0.709). 폐 영역 모델 0.775 ± 0.035 (0.735 / 0.796 / 0.794)	○ **미달** (기준) · 폐 모델은 평균만 달성
Q1 폐렴 민감도 ≥ 0.95 (세균성+바이러스성 묶음)	기준 모델 0.995~0.997 (387장 중 정상으로 놓친 폐렴 1~2장), 폐 영역 모델 0.995~0.997	● **달성**
Q2 세균↔바이러스 혼동 유형 3개 이상 도출	혼동행렬로 방향은 확인(test, seed 42: 바이러스성 147장 중 51장이 세균성으로, 세균성 240장 중 6장이 바이러스성으로). 오분류 사진을 보고 유형으로 나누는 작업은 하지 못함	◐ **부분**
Q3 정답 예측의 평균 LFR ≥ 0.70	열지도 중 폐 안 비율 정답 사진 평균 **0.319** (폐 면적 비율 0.358), val 1,030장. 열지도가 폐에 몰리지 않음	○ **미달**
Q4 Endpoint 예측 = 로컬 예측 (라벨 100%, 확률 차이 < 1e-4)	val 20장 예측 20/20 일치, 확률 최대 차이 7.5e-6 (비교 대상은 SageMaker Notebook이 아닌 내 컴퓨터의 같은 모델)	● **달성**
Q5 사진 1장 응답 ≤ 3초 (Grad-CAM 포함)	화면 → Lambda → Endpoint 전체 경로 1.1초 (확률 3개만, Grad-CAM 없음)	◐ **부분**
Q6 보호자 설명: 문장 오류 0건, 이해도 ≥ 4.0	규칙 기반 설명문을 구현해 결과 8종류 모두 오류 없이 실행(224 모델 D 기준). 이해도 평가(10건)와 보호자용 4단 문장 틀은 하지 않음	○ **미실시**
Q7 전처리별 비교표 완성, 검증 기준으로 선정	P0~P4의 val Macro-F1·클래스별 recall·장비 차이 시험·test 점수 비교표 완성(224, 부록 B). LFR 비교는 하지 않음. 원본(P0) 유지	◐ **부분**

2.4 알려 둘 사항 (사전 계획과 달라진 점)

> **기준 모델을 test를 본 뒤에 바꿨다.** 10/14 기획안과 10/19 평가 계획(해시 고정)이 지정한 최종 모델은 실험 D(노이즈 증강, 224)였다. 그런데 연구 질문이 '기본 모델의 민감도'여서, test를 본 뒤 기준을 B 설정(증강 없음)으로 바꿨다. 두 모델의 test 점수는 B 0.719 [0.677, 0.757], D 0.692 [0.652, 0.732]로 구간이 겹쳐 어느 쪽이 낫다고 말할 수 없었고, 둘 다 보고한다 (부록 B).
>
> **test는 여러 번 열렸다.** 224 모델 8개에 한 번씩, B512 계열은 모델마다 한 번씩 평가했다. B512 계열은 평가 계획 문서와 sha256 해시를 먼저 고정하고 실행했으며, **결과를 보고 모델·필터·강도를 바꾸지 않았다.** 다만 장비 효과 증강과 폐 영역 모델을 설계할 때 B512의 test 결과를 이미 알고 있었다는 점을 각 계획 문서 1장에 밝혔다. 가이드는 test 점수를 보고 설정을 반복해서 조정하지 말라고 한다. 이 프로젝트는 알고 있던 test 결과로 설계를 바꾸지 않았고(설계 근거는 val 결과와 장비 물리 지식뿐), 다만 이미 열린 데이터라는 한계는 남는다.

3 데이터와 분할

3.1 데이터

Kermany 등(2018)이 공개한 광저우 여성아동의료센터 1~5세 소아 흉부 X선(전후면) 5,856장이다. 폐렴 폴더의 파일명(bacteria / virus)으로 세균성·바이러스성 라벨을 만들었고, 파일명은 라벨을 만드는 데만 쓰고 모델 입력에는 넣지 않았다. 원래 분할은 train 5,216장(정상 1,341 / 세균성 2,530 / 바이러스성 1,345), val 16장(8 / 8 / 0), test 624장(234 / 242 / 148)이다.

3.2 분할

원래 val은 16장뿐이고 **바이러스성이 0장**이라 검증셋으로 쓸 수 없었다. 그래서 원래 train 5,216장에서 **환자 그룹 단위·클래스 층화** (StratifiedGroupKFold, seed 42, 5등분의 한 조각)로 학습과 검증을 다시 나눴다. test 624장은 원래대로 두었다. 환자 그룹은 파일명의 환자 번호(personN)로 묶었고 같은 번호는 한 덩어리로 다뤄 같은 환자가 학습과 검증에 섞이지 않게 했다. 같은 파일(sha256 동일)도 같은 쪽에 두었다.

구분	정상	세균성	바이러스성	합계	환자 그룹	용도
train	1,075	2,042	1,069	4,186	2,277	학습
val	266	488	276	1,030	569	에폭 선택·개발·필터 시험
check	8	8	0	16	15	화면·입출력 점검 (원래 val, 점수 계산 안 함)
test	234	242	148	624 (평가 618)	427 (426)	최종 확인

분할 규칙과 근거: `manifests/split_report.md` , 점검 결과: `reports/seed_check_and_split_balance.md` . 분할 파일의 sha256은 `205286f33fe23aac…` (모든 실험이 같은 파일을 썼다).

3.3 점검한 것

- **train과 val의 분포는 같다.** 클래스별 val 비율 19.3~20.5%, 그룹 수·그룹당 사진 수·저장 품질·가로세로 비율이 거의 같다.
- **test 안에 같은 사진 6쌍**(sha256 동일)이 있어 평가에서 사본 6장을 빼고 **618장**(정상 231 / 세균성 240 / 바이러스성 147, 환자 그룹 426)으로 평가했다.
- 원래 train과 test에 같은 번호의 환자 그룹 170개(457장)가 있으나 모두 병이 서로 달라(같은 병이 겹치는 것 0) 제거하지 않았고, test에서 누수의 증거는 확인하지 못했다.
- 세균성 사진이 바이러스성의 약 1.9배다(환자 수로는 약 1.2배: 세균성 환자 1명당 사진이 많다). 클래스 가중치(실험 C)는 효과가 작아 최종 설정에 넣지 않았다.

3.4 test의 정상 사진은 train·val의 정상 사진과 다르다

val은 train에서 떼어 낸 것이라 train과 같은 분포인데, test의 정상 사진은 다른 묶음이다. 아래는 사진 파일 자체의 특성이다.

특성	train·val 정상	폐렴 (train)	test 정상
JPEG 저장 품질	약 96	약 75	**약 75**
포토샵 처리 기록이 있는 사진	100%	2~5%	**0%**
원본 가로세로 비율 (중앙값)	1.22	1.48~1.51	**1.35**
폐 상자가 사진 세로를 채우는 비율 (중앙값)	0.729	0.846	**0.838**

train·val의 정상 사진은 모두 품질 약 96으로 저장되고 포토샵 처리 기록이 있는 반면, 폐렴 사진과 test 정상 사진은 품질 약 75에 기록이 없다. 파일 속성만으로 정상/폐렴을 맞히는 분류기가 train 안에서는 거의 완벽(AUROC ≈ 1.00)한데 test에서는 0.75로 내려간다 (`reports/test_eval/normal_shift/`). 이 차이가 **val 점수가 test 점수를 예측하지 못하는 이유의 후보**이고(6장), 확인된 원인은 아니다. 이 때문에 test 정상 사진의 절대 점수보다 **같은 모델의 필터 전후 변화량과 방향**을 중심으로 해석했다.

4 방법

4.1 기준 모델 B512

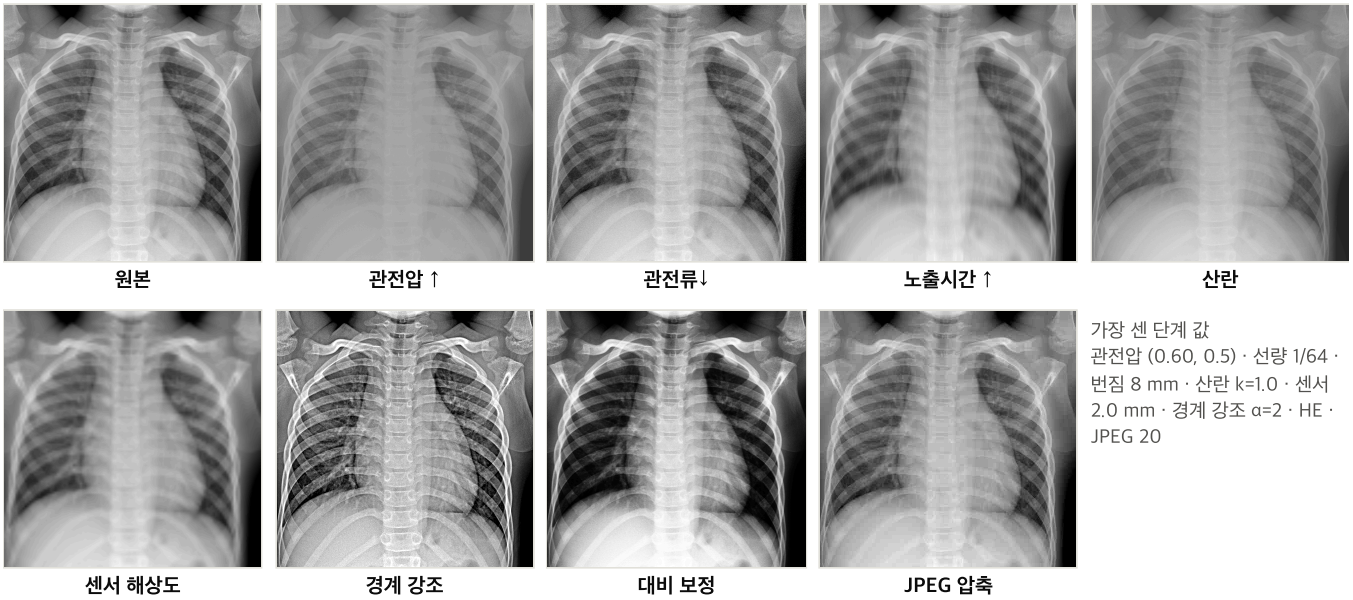
'아무것도 더하지 않고 그냥 돌린 기본 모델'을 기준으로 삼았다 (증강·전처리 없이 마지막 잔차 블록 layer4와 출력층만 학습한 ResNet18).

항목	내용	항목	내용
백본	ResNet18, ImageNet 사전학습 가중치, 출력층 fc 512 → 3	학습하는 층	layer4 + fc (나머지는 고정)
입력	512×512. 회색 사진을 3채널로 복제하고 ImageNet 값으로 정규화. 가로세로는 정사각형으로 눌러 맞춤	증강·전처리	없음 (기준 모델)
손실·최적화	Cross-Entropy, Adam (fc 학습률 0.001, layer4 학습률 0.0001)	배치·에폭	배치 16, 최대 30에폭
에폭 선택	val Macro-F1이 가장 높은 에폭 (선택 규칙은 학습 전에 고정)	seed	42 · 43 · 44 (선택된 에폭 18 / 28 / 18)
학습 환경	SageMaker 학습 작업, ml.g4dn.2xlarge (T4), PyTorch 2.2 컨테이너. 학습 시간 886 / 884 / 893초	코드	`training/train.py` (기준) `train_aug.py` (장비 효과 증강) `train_lung.py` (폐 영역)

4.2 장비 설정 필터 8종

흉부 X선 장치에서 설정을 바꾸면 영상에 생기는 효과를 고전 영상처리로 만들었다. **장비의 변수를 직접 조절한 것이 아니라 그 변수가 만드는 결과를 흉내 낸 것**이다. 필터마다 약·중·강 3단계, 시험 조건은 8종 × 3단계 = 24개다 (부록 A에는 흐림·밝게·어둡게 9개를 더한 33조건). 필터는 모델이 실제로 보는 512×512 회색 사진에 직접 걸었고, 길이는 '모델 입력에서 1 mm = 2.29픽셀'로 통일했다.

구분	필터	장치에서 일어나는 일	구현	약 · 중 · 강
장비 설정 5종 (학습에도 씀)	**관전압** ↑ (kVp)	관전압이 높으면 영상의 대비가 줄고 뼈가 덜 하얘진다	평균 기준으로 대비를 줄이고 밝은 쪽을 눌러 줌	(대비 배율, 밝은 쪽 기울기) (0.85, 0.8) · (0.70, 0.6) · (0.60, 0.5)
	관전류↓ (선량)	선량이 줄면 광자가 줄어 양자 노이즈가 늘어난다 (노이즈 ∝ 1/√선량)	노출량에 비례하는 노이즈를 더함	상대 선량 1/4 · 1/16 · 1/64 (노이즈 추정 2.1 · 4.0 · 7.9배)
	노출시간 ↑	오래 찍으면 아이가 움직여 세로로 번진다	세로 방향 상자 필터 (사진 위 25% → 아래 100%로 갈수록 크게)	번짐 길이 2 · 4 · 8 mm
	산란 (격자 없음)	산란선이 안개처럼 깔려 작은 구조의 대비가 줄어든다	(원본 + k × 크게 흐린 사진) ÷ (1 + k)	k = 0.25 · 0.5 · 1.0 (폭 25 mm)
	센서 해상도	화소가 커지면 미세한 무늬가 뭉개진다	화소 안에서 평균을 낸 뒤 다시 키움	화소 0.5 · 1.0 · 2.0 mm
제조사 후처리·전송 3종 (학습에는 쓰지 않음)	**경계 강조**	제조사의 선명화 후처리 (대표 기법으로 대신함)	언샤프 마스킹	α = 0.5 · 1.0 · 2.0
	대비 보정	제조사의 대비 보정 (대표 기법으로 대신함)	CLAHE 또는 히스토그램 평활화	CLAHE 1.5 · CLAHE 3.0 · HE
	JPEG 압축	전송·저장 과정의 손실 압축	JPEG으로 다시 저장	품질 75 · 40 · 20



가장 센 단계 값
관전압 (0.60, 0.5) · 선량 1/64 · 번짐 8 mm · 산란 k=1.0 · 센서 2.0 mm · 경계 강조 α=2 · HE · JPEG 20

그림 1. 같은 사진(train 정상)에 필터를 가장 센 단계로 건 모습. 보기 쉽도록 가운데 정사각형으로 잘랐고(모델 입력은 눌러서 맞춤) 필터 코드와 강도는 시험과 같다. 이 사진 한 장에서 눈에 띄는 정도는 필터마다 다르다.

- 강도는 **시험 전에 문서(`reports/equipment_v2/strength_fixed_512.md`)로 고정**했다. 224판 시험의 점수를 본 뒤 단위만 정리했고(입력을 224에서 512로 옮기며 mm 단위 통일), 이후 점수를 보고 바꾸지 않았다.
- **필터끼리 강도가 보정되지 않았다.** 예를 들어 관전압 '강'은 가운데 척추·심장 부위가 거의 평평해질 만큼 세다. 그래서 필터 사이의 점수 하락을 직접 비교하지 말고 '어느 필터에서 크게 떨어지는가'의 순서 정도로만 읽는다.
- 선량 필터의 기준 노이즈는 원본 사진의 노이즈 추정에 맞춘 값이고 모델 점수는 쓰지 않았다. 8비트 JPEG라 실제 톤 곡선을 모르고, 관전압은 뼈와 연부조직의 에너지 의존 대비를 만들지 못해 근사했다.
- 제외한 필터: 흐림(초점·거리 번짐), 밝게·어둡게(노출·표시 설정)는 장비 설정 분류에 들어가지 않아 본편에서 뺐고 결과는 부록 A에 남겼다.

4.3 폐 영역 모델 (시험 ②)

공개 폐 분할 모델 PSPNet(TorchXRayVision)이 좌·우 폐를 칠하고, 그 **볼록 껍질 + 16픽셀** 밖을 검게(0) 지운 사진으로 같은 방식(B512 설정 그대로, seed 3개)으로 학습한 것이 **폐 영역 모델(l)**이다. 자르거나 확대하지 않고 사진 크기를 그대로 둔다. 필터는 **먼저 걸고 같은 고정 마스크를 씌운다** (마스크 뒤에 거는 순서는 산란·관전압·대비 보정에서 폐 안쪽까지 다르게 만들어 쓰지 않았다). 폐 면적이 사진의 5% 미만이면(분할 실패) 사진 전체를 쓴다 — 5장(train 4, val 1), 모두 세균성이었다 (폐가 하얗게 찬 사진에서 PSPNet이 공기가 찬 조각만 잡음).

4.4 장비 효과 증강 (시험 ③)

학습 사진의 **50%**에 장비 설정 필터 5종 중 하나를 골라 **무작위 세기 u ~ U(0, 1)**로 건다 (u = 1이 시험의 '강'과 같고, u = 0이 원본과 같다). 경계 강조·대비 보정·JPEG은 학습에 쓰지 않고 **'처음 보는 유형'**으로 남겼다. 기준 모델에 적용한 것이 **증강 모델(v)**, 폐 영역 모델에 적용한 것이 **폐**

영역 + 증강 모델(lv)이다. 에폭 선택 규칙은 기준과 같고(필터를 안 건 val 점수가 가장 높은 에폭), 증강은 학습에만 쓴다. 증강 코드: `training/train_aug.py --augment equip`.

4.5 평가 방법

- 지표: Macro-F1(주 지표, 세 클래스 F1의 평균), 클래스별 recall, Macro AUROC. 필터 효과는 **같은 모델의 원본 점수 대비 변화**로 보고, 95% 구간은 **환자 묶음 단위 짝지은 bootstrap 1,000회**(같은 환자의 사진을 함께 뽑음)로 구한다.
- val 1,030장은 개발·선택용이다. test 618장에는 모델마다 **평가 계획 문서(`reports/equipment_v2/test_plan_*.md`)와 sha256 해시를 먼저 고정한 뒤 한 번만** 필터 33조건을 걸었다 (평가 코드 `src/equipment_eval_direct.py`, 필터를 안 건 점수가 학습 기록과 같은지 자동 검증).
- 묶음 비교: 같은 환경의 모델끼리, 평균 차이가 **기준 묶음 표준편차(seed 3개, ddof=1)의 2배 이상**이면 '차이 있음', 아니면 '말할 수 없음'. 표준편차가 seed 3개에서 나온 거친 값이라 판정은 엄격하다. 이 규칙은 결과를 보기 전에 정했고 바꾸지 않았다.
- 학습에 쓴 필터 5종을 건 점수는 **'배운 유형'**이라 방어력의 증거로 쓰지 않는다. 처음 보는 3종과 필터를 안 건 원본 점수가 방어력을 보는 부분이다.

5 결과

5.1 기준 모델의 점수

모델	선택 에폭	val F1	val AUROC	val 정상 recall	test F1	test AUROC	test 정상 recall	test 폐렴을 정상으로 놓친 장 (민감도)
B512 s42	18	0.843	0.940	0.985	0.670	0.906	0.446	1장 (0.997)
B512 s43	28	0.844	0.944	0.992	0.736	0.919	0.532	2장 (0.995)
B512 s44	18	0.832	0.934	0.985	0.709	0.925	0.472	1장 (0.997)
평균 ±SD		**0.839 ± 0.007**	**0.939 ± 0.005**	**0.987 ± 0.004**	**0.705 ± 0.033**	**0.917 ± 0.009**	**0.483 ± 0.044**	

기준 모델의 val 점수는 0.839 ± 0.007, 같은 모델에 test 618장을 한 번씩 넣으면 0.705 ± 0.033다. 가장 크게 달라진 것은 **정상 사진**이다. val에서 정상을 98.7% 맞히던 모델이 test에서는 48.3%만 맞힌다 (정상 231장 중 128장을 폐렴으로 판정, seed 42). 반대로 폐렴을 정상으로 놓친 사진은 387장 중 1~2장뿐이다. 이 모델은 **정상을 폐렴이라고 말하는 쪽으로** 틀린다. 같은 설정으로 학습을 다시 해도 test F1이 0.670~0.736으로 흔들려서, 'test 0.70'은 고정된 값이 아니다.

정답 \ 예측 (test 618장, seed 42)	정상	세균성	바이러스성
정상 (231)	103	38	90
세균성 (240)	1	233	6
바이러스성 (147)	0	51	96

5.2 시험 ①: 필터를 걸면 점수가 얼마나 떨어지는가

기준 모델 3개(seed 42·43·44)에 필터 8종을 약·중·강으로 걸어 원본 대비 점수 변화를 쟀다. 그림 2는 가장 센 단계만, 전체 조건은 부록 A에 있다.

- **장비 설정 5종이 크게 흔들었다.** val에서 관전압(−0.173), 노출시간(−0.110), 센서 해상도(−0.098), 산란(−0.076) 순이었고, test에서는 같은 필터들이 더 크게 떨어졌다(−0.231, −0.209, −0.158, −0.152). 관전류(선량)가 가장 약했다(−0.037 / −0.062).
- 후처리·전송 3종 중 경계 강조는 val에서 −0.073였지만 **test에서는 오히려 올랐다**(+0.024). 약한 단계에서 test 정상 recall이 0.446에서 0.515으로 올랐고, 원인은 확인하지 못했다. JPEG은 두 곳 모두 떨어졌다(−0.070 / −0.115).
- 한 모델(seed 42)로 보면 val의 본편 24조건 중 **17개**, test는 19개의 변화가 95% 구간에서 0이 아니었다 (전체 33조건표는 부록 A).
- **쏠림의 방향:** 관전압 '강'을 걸면 val 정상 사진의 recall이 0.985에서 0.406으로 떨어지고 바이러스성으로 예측하는 비율이 24%에서 51%로 늘었다. 노출시간 '강'에서는 바이러스성이 24% → 12%로 줄고 세균성 예측이 늘었다. 이 방향은 모델마다 다를 수 있어(224 입력 모델은

노이즈에서 바이러스성 쪽으로 쏠렸다) 일반화하지 않는다.

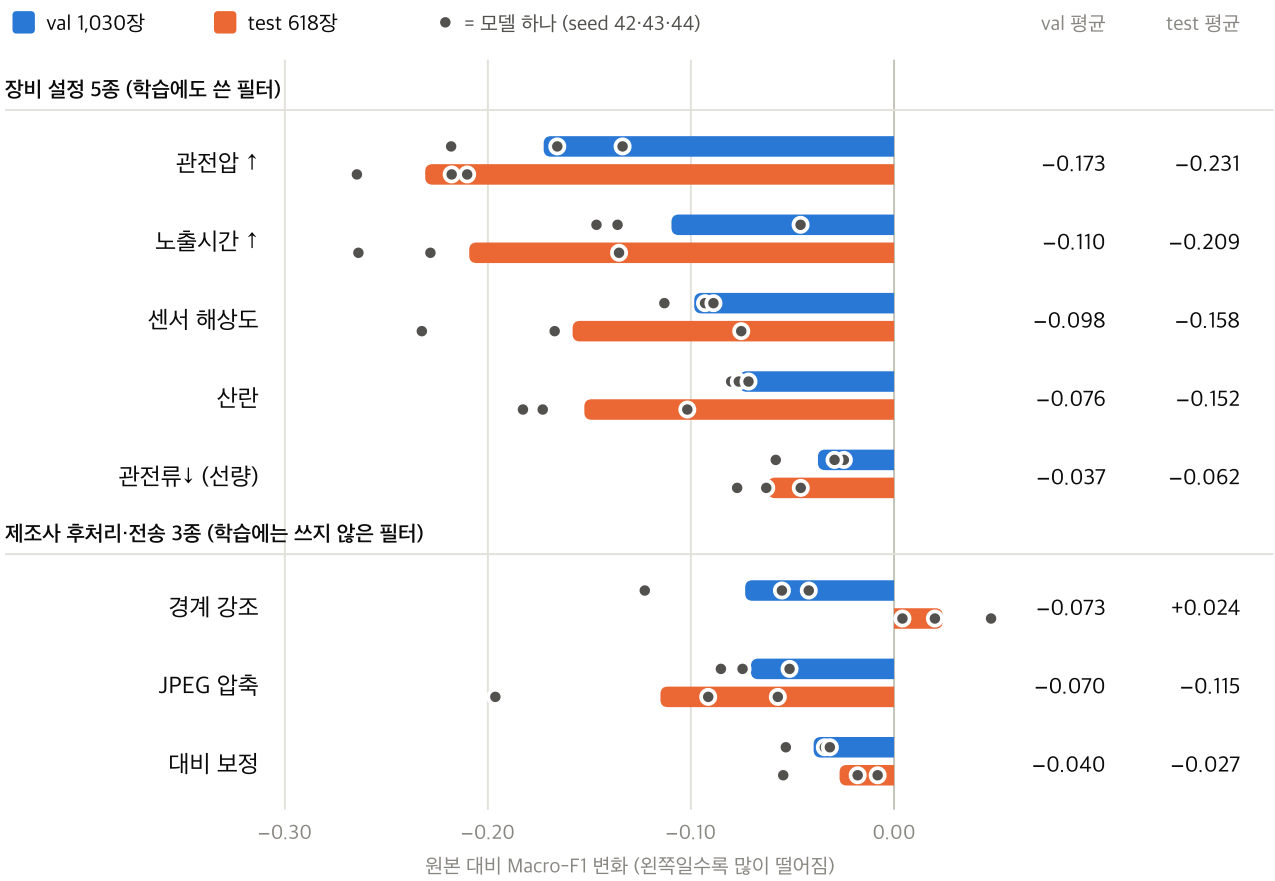


그림 2. 필터 8종을 가장 센 단계로 걸었을 때 원본 점수 대비 Macro-F1 변화. 막대는 기준 모델 3개의 평균, 점은 모델 하나다. 위 5개는 학습에도 쓴 장비 설정, 아래 3개는 학습에 쓰지 않은 후처리·전송이다. 필터끼리 강도가 보정되지 않았으므로 막대 길이를 필터 사이에서 그대로 비교하지 않는다.

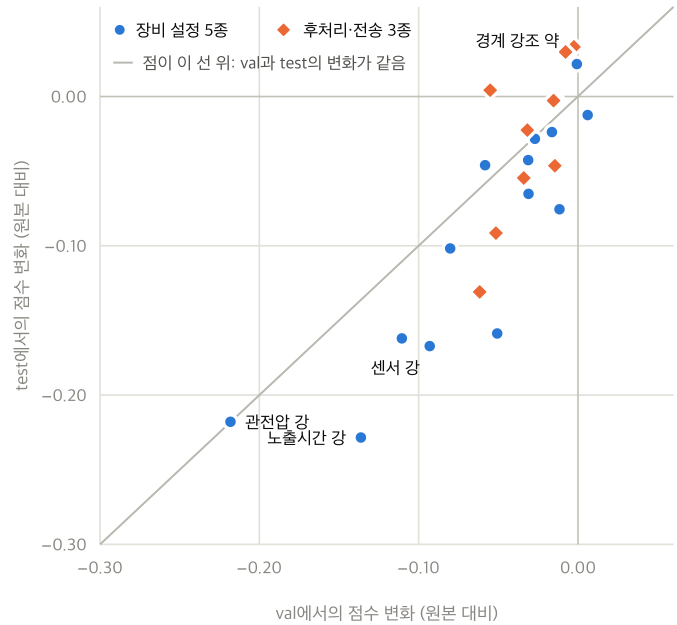


그림 3. 같은 조건에서 val의 점수 변화(가로)와 test의 변화(세로), 기준 모델 seed 42, 본편 24조건 (점 하나 = 조건 하나).

val에서 본 것이 test에서도 같은 방향이다. 24조건의 변화량 순위상관이 **0.79**(피어슨 0.85), 둘 다 떨어진 조건이 19개다. 예외는 test에서 점수가 오른 경계 강조 약·중과 센서 약 조건이다.

test는 정상 사진 집단이 달라(3.4절) 절대 점수가 낮고 seed마다 크게 흔들린다. 그래서 test는 val에서 본 순서가 반복되는지만 확인하는 용도로 썼다. 세 모델(seed)에서도 관전압·노출시간·센서가 크게 떨어지는 것은 같았고 크기는 seed마다 달랐다 (그림 2의 점).

5.3 시험 ②: 폐만 남겨도 같은가

폐 영역 모델은 원본 점수가 기준 모델과 비슷하거나(val) 더 높은(test) 반면, 필터에 약한 정도는 비슷했다.

	지표	기준 모델 (AWS 3개)	폐 영역 모델 (3개)	차이	기준 SD의 몇 배	판정
val	원본 사진 Macro-F1	0.839 ± 0.007	0.826	−0.013	−2.0배	말할 수 없음
val	원본 사진 AUROC	0.939 ± 0.005	0.928	−0.011	−2.2배	**차이 있음 ↓**
val	원본 사진 정상 recall	0.988 ± 0.004	0.959	−0.029	−6.6배	**차이 있음 ↓**
val	필터 24조건 평균 F1	0.795 ± 0.009	0.772	−0.023	−2.6배	**차이 있음 ↓**
val	필터 24조건 평균 하락 (원본 대비)	−0.044 ± 0.004	−0.054	−0.010	−2.3배	**차이 있음 ↓**
test	원본 사진 Macro-F1	0.705 ± 0.033	0.775	+0.070	+2.1배	**차이 있음 ↑**
test	원본 사진 AUROC	0.917 ± 0.009	0.944	+0.027	+2.9배	**차이 있음 ↑**
test	원본 사진 정상 recall	0.483 ± 0.044	0.605	+0.121	+2.7배	**차이 있음 ↑**
test	필터 24조건 평균 F1	0.639 ± 0.044	0.705	+0.066	+1.5배	말할 수 없음
test	필터 24조건 평균 하락 (원본 대비)	−0.066 ± 0.018	−0.070	−0.004	−0.2배	말할 수 없음

판정의 화살표: ↑ 폐 영역 모델이 더 높음, ↓ 더 낮음 (하락 행은 값이 클수록 덜 떨어졌다는 뜻). 두 묶음의 평균 차이가 기준 묶음 표준편차의 2배 이상일 때만 '차이 있음'.

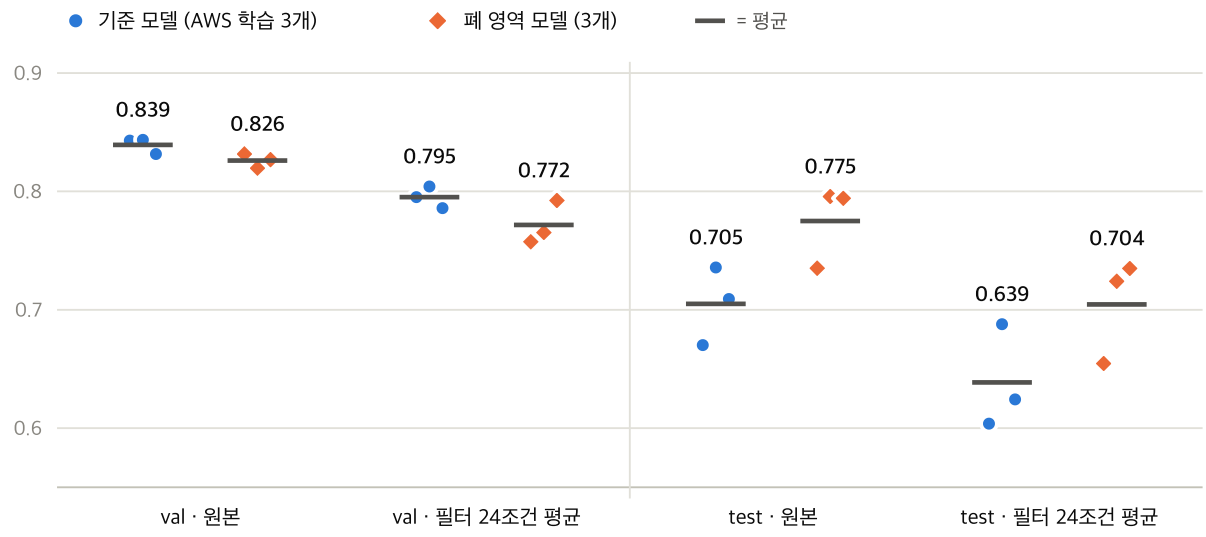


그림 4. 기준 모델 3개와 폐 영역 모델 3개의 Macro-F1. 점은 모델 하나, 막대는 평균. 두 모델 모두 필터를 걸면(오른쪽 열) 원본(왼쪽 열)보다 낮아진다.

- **원본 점수:** val에서는 폐 영역 모델이 낮거나 같고(F1은 말할 수 없음, AUROC·정상 recall은 낮음), test에서는 높다(F1 0.775 대 0.705, 기준 SD의 2.1배 → '차이 있음'의 문턱 근처). 환경이 다른 JupyterLab 기준과 비교하면 1.5배로 규칙에 못 미쳐, **'폐 영역 모델의 test 점수가 더 높다'는 결과는 견고하지 않다.** 같은 폐 영역 모델이 val에서는 약간 낮은 점은 폐 밖 단서가 val(같은 병원·같은 분포)에서는 도움이 되었을 가능성과 맞지만 증명은 아니다.
- **필터 약점:** 24조건 평균 하락이 val −0.044(기준) 대 −0.054(폐 영역), test −0.066 대 −0.070으로 **폐 밖을 지워도 약점이 그대로 남았다.** 필터로 점수가 떨어지는 것이 폐 밖 단서를 쓰는 이 모델만의 현상은 아니라는 뜻이다.
- 이 시험의 한계: 폐 마스크는 필터 없는 사진에서 만든 것이라 분할 모델 자체의 강건성은 들어 있지 않다. 분할은 병이 심한 쪽(폐가 하얗게 찬 세균성 사진)에서 틀리고, 폐 모양이 새로운 단서가 될 수 있다.

5.4 시험 ③: 장비 효과를 섞어서 학습하면

기준 모델과 폐 영역 모델 각각에 장비 효과 증강을 적용해 각 3개씩 학습했다. 증강 전 모델과 같은 환경끼리 비교한다 (기준: JupyterLab, 폐 영역: AWS 학습 작업).

	지표	증강 전 (JupyterLab 기준 3개)	증강 후 (v 3개)	차이	판정
val	필터를 안 건 원본 Macro-F1	0.836 ± 0.005	0.831	−0.005	말할 수 없음
val	원본 정상 recall	0.983 ± 0.002	0.980	−0.003	말할 수 없음
val	연습에서 본 필터 5종 (15조건 평균 F1)	0.774 ± 0.001	0.815	+0.041	**차이 있음 ↑**
val	못 본 필터 3종 (9조건 평균 F1)	0.811 ± 0.007	0.802	−0.009	말할 수 없음
test	필터를 안 건 원본 Macro-F1	0.712 ± 0.043	0.741	+0.029	말할 수 없음
test	원본 정상 recall	0.492 ± 0.074	0.545	+0.053	말할 수 없음
test	연습에서 본 필터 5종 (15조건 평균 F1)	0.580 ± 0.041	0.700	+0.120	**차이 있음 ↑**
test	못 본 필터 3종 (9조건 평균 F1)	0.694 ± 0.062	0.706	+0.012	말할 수 없음

	지표	증강 전 (폐 영역 I 3개)	증강 후 (Iv 3개)	차이	판정
val	필터를 안 건 원본 Macro-F1	0.826 ± 0.006	0.817	−0.009	말할 수 없음
val	원본 정상 recall	0.959 ± 0.010	0.950	−0.009	말할 수 없음
val	연습에서 본 필터 5종 (15조건 평균 F1)	0.768 ± 0.023	0.796	+0.028	말할 수 없음
val	못 본 필터 3종 (9조건 평균 F1)	0.778 ± 0.013	0.790	+0.012	말할 수 없음
test	필터를 안 건 원본 Macro-F1	0.775 ± 0.035	0.773	−0.002	말할 수 없음
test	원본 정상 recall	0.605 ± 0.078	0.600	−0.004	말할 수 없음
test	연습에서 본 필터 5종 (15조건 평균 F1)	0.660 ± 0.048	0.721	+0.061	말할 수 없음
test	못 본 필터 3종 (9조건 평균 F1)	0.779 ± 0.040	0.734	−0.045	말할 수 없음

판정의 화살표: ↑ 증강 후가 더 높음. 연습에서 본 필터 5종은 학습에 섞은 것이라 방어력의 증거가 아니다.

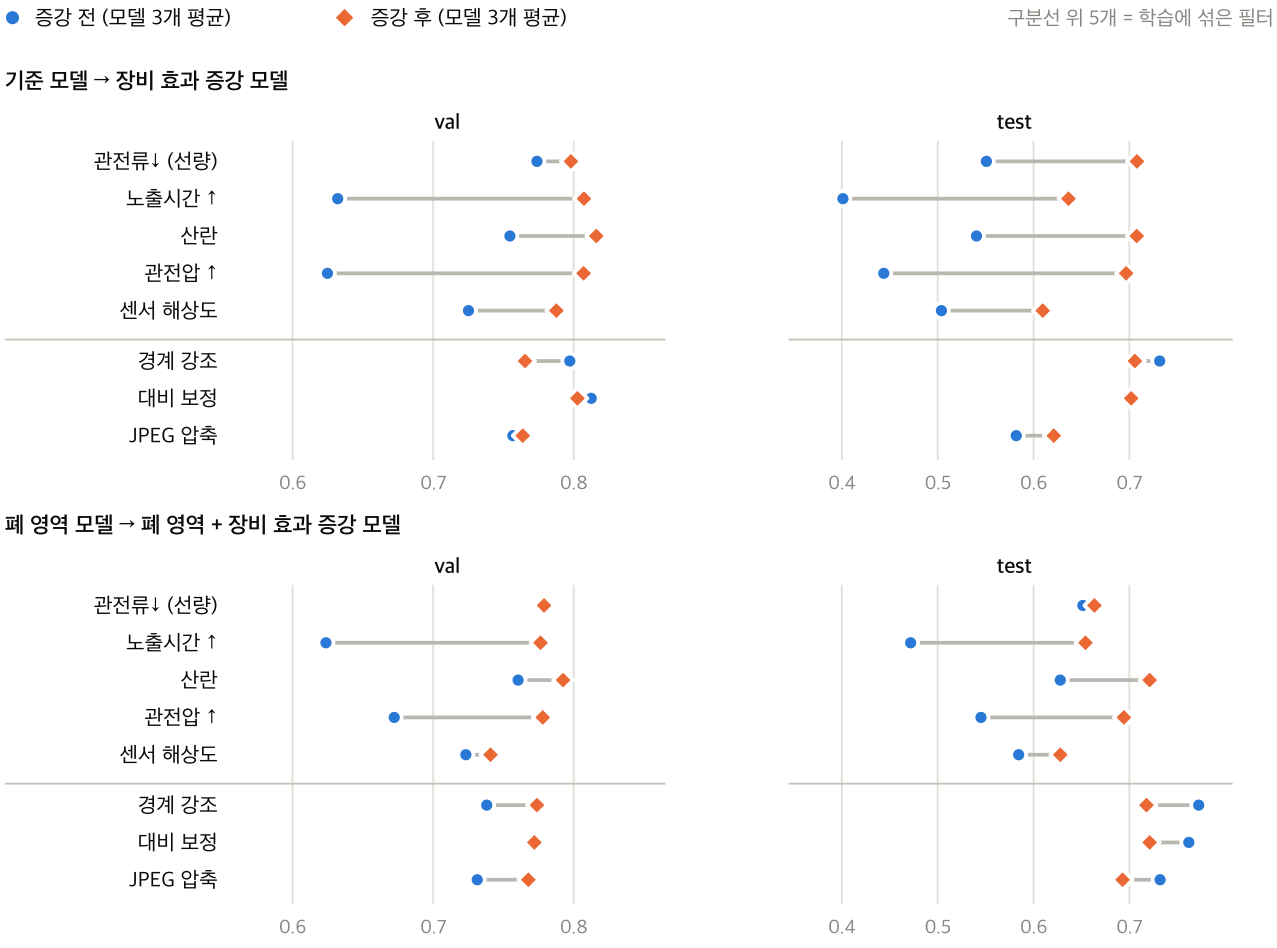


그림 5. 증강 전(파랑 원)과 후(주황 마름모)의 가장 센 단계 Macro-F1, 모델 3개 평균. 가로축 범위는 val과 test가 다르다. 구분선 위 5개가 학습에 섞은 필터다.

- **연습한 필터에서는 올랐다.** 기준 모델은 val 0.774 → 0.815, test 0.580 → 0.700으로 둘 다 '차이 있음'이고, 특히 노출시간과 관전압에서 컸다 (test 0.401 → 0.636, 0.444 → 0.697). 폐 영역 모델도 같은 방향이다(test 0.660 → 0.721). 다만 폐 영역 모델은 seed 편차가 커서 '말할 수 없음'이다.
- **그러나 이것은 같은 종류의 필터로 본 시험이다.** 학습에 섞은 필터를 시험에도 썼으므로 '실제 장비에 강해졌다'는 증거가 아니다. 방어력을 볼 수 있는 부분은 학습에 쓰지 않은 3종과 원본 점수다.
- **못 본 필터 3종과 원본 점수는 나아졌다고 말할 수 없다.** 기준 모델은 못 본 3종이 val 0.811 → 0.802, test 0.694 → 0.706, 원본 점수 val 0.836 → 0.831, test 0.712 → 0.741로 모두 '말할 수 없음'이다. 폐 영역 모델은 못 본 3종이 test에서 0.779 → 0.734로 낮아졌으나 이것도 '말할 수 없음'이다. 증강이 원본 점수를 해치지는 않았다.
- 따라서 이 실험으로 말할 수 있는 것은 '**배운 유형의 장비 효과에는 강해진다**'까지이고, '장비가 바뀌어도 괜찮다'는 아니다. 필터는 실제 장비가 아니라는 한계(8장)가 그대로 남는다.

6 점수를 믿을 수 있는가: 진단

6.1 val 점수는 test를 예측하지 못했다

정상 사진의 recall이 val 0.987에서 test 0.483으로 떨어지는 현상은 기준 모델만의 것이 아니다. 초기 224 모델 8개도 모두 val에서 정상 recall 0.955~0.989였다가 test에서 0.433~0.632로 떨어졌고(부록 B), 어떤 변화(클래스 가중치·노이즈 증강·전처리·해상도)를 줘도 이 낙폭은 사라지지 않았다. 모델 8개의 val 순위와 test 순위의 순위상관은 −0.50이라 **val 점수가 test 점수를 예측하지 못했다.** val은 train에서 떼어 낸 같은 분포라 이 차이를 잡을 수 없다 (3.4절). 틀린 정상 사진은 확신도 높게 틀린다 (224 모델 D: 정상을 폐렴으로 본 129장 중 113장이 최대 확률 0.70 이상이라 '판단 보류' 규칙에 걸리지 않음).

6.2 원인 후보와 확인한 것

원인 후보	시험	결과	판단
정상 사진의 **저장 방식** (품질 96 + 편집 기록 대 품질 75)	val 정상 사진을 품질 75로 다시 저장해 넣음 (B 224, D 224, B448)	예측이 바뀐 정상 사진 0~1장 (1,030장 중)	**단독 원인은 아님**
가로세로 비율	val 사진의 내용을 가로로 늘려 test 정상 사진의 비율처럼 만들어 B512에 넣음	정상 recall 0.985 → 0.981 (비율 0.905), 0.985 (1.22)	**재현되지 않음** (이 방식은 폐의 세로 점유를 바꾸지 못함)
폐가 사진 세로를 채우는 정도	test 정상 231장을 폐 상자 세로 점유 3분위로 나눠 B512 seed 42의 정상 recall을 봄	낮음 0.597 / 중간 0.468 / 높음 0.273, 상관 −0.36	**연관 있음** (인과 아님). 폐 상자로 자르는 재학습은 하지 않음
파일 속성의 지름길	파일 속성(크기·JPEG 품질·메타데이터 등)만으로 정상/폐렴을 맞히는 분류기	train 안에서 AUROC ≈ 1.00, test 0.75	데이터에 지름길이 있다는 사실. 모델이 쓰는지는 **미확인**
test 정상 사진 **집단 자체**의 차이	나이·촬영 자세·촬영 시기 등	데이터로 확인할 수 없음	**모름**

결론: test 점수가 낮은 원인은 확정하지 못했다. 시험한 요인 하나만으로는 낙폭이 재현되지 않았고, 구도(폐가 사진 세로를 채우는 정도)가 가장 유력한 연관이다. 강사 의견(정상과 환자 폐의 비율 때문이고 폐 영역 상자로 크롭하면 잘 나온다)과 방향이 맞는 정황이지만 크롭 재학습은 하지 않았다.

6.3 모델은 어디를 보는가 (Grad-CAM)

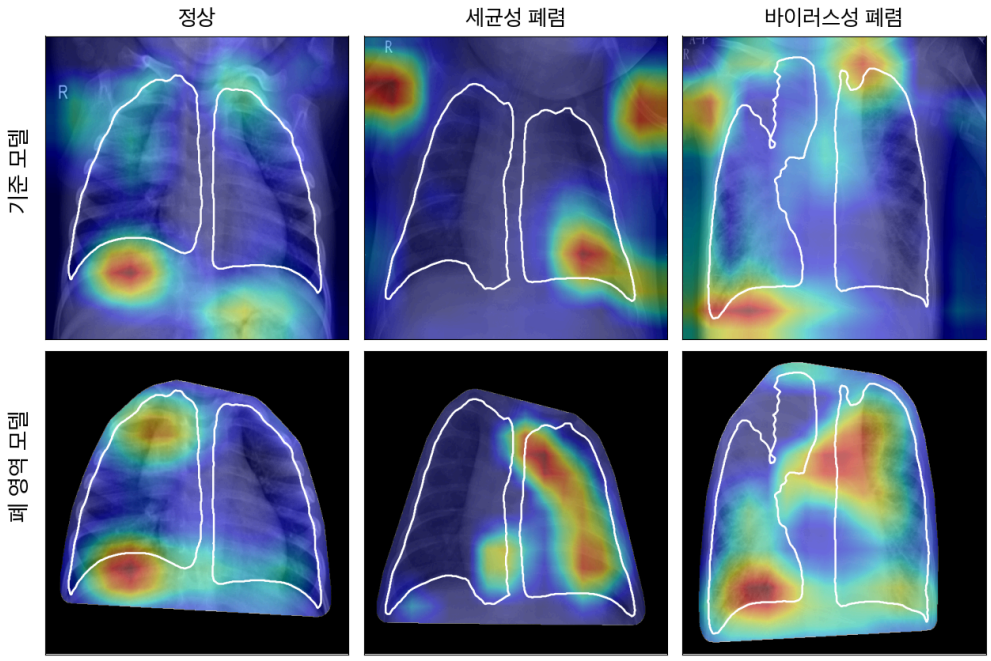


그림 6. 예시 3장(val, 두 모델이 모두 맞힌 사진)의 Grad-CAM. 흰 선은 PSPNet이 찾은 폐 윤곽이다. 위: 기준 모델, 아래: 폐 영역 모델. 한 장씩의 예시이므로 일반화하지 않고 아래 평균 수치로 판단한다.

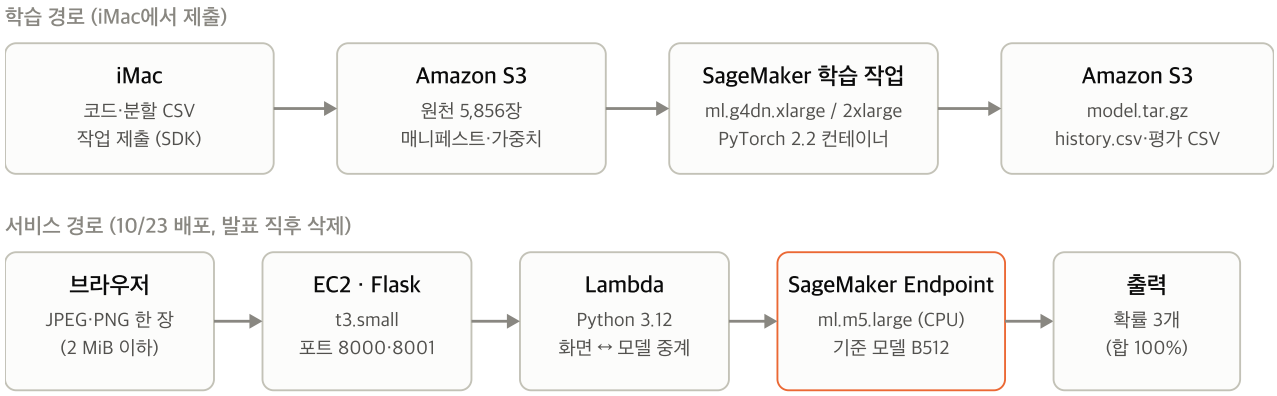
모델 (val 1,030장)	열지도 중 폐 안 비율	폐 면적 비율	최고점이 폐 안인 사진	정답 정상 사진 중 최고점이 폐 안
B512 (기준, AWS s42)	0.319	0.358	20.9%	3.4%
b-s42 (기준, JupyterLab)	0.354	0.358	28.7%	13.5%
v-s42 (장비 효과 증강)	0.285	0.358	15.2%	2.3%

val 1,030장, 폐 마스크는 PSPNet(12장만 눈으로 확인). 지도가 고르게 퍼졌다면 폐 안 비율은 폐 면적 비율과 같고 최고점이 폐 안일 확률은 약 36%다.

- **구현은 맞다.** 훅 없이 layer4 출력과 fc 가중치로 직접 만든 지도와 상관 1.000000, 최대 절대 차이 4.17e-07 (val 300장).
- **열지도는 폐에 몰리지 않는다.** 기준 모델 열지도 중 폐 안 비율은 0.32로 폐 면적 비율(0.36)과 같거나 낮고, 최고점은 폐 밖(가장자리, 어깨·목, 횡격막·복부, 글자 R)에 더 많다. 정상 정답 사진은 최고점이 폐 안인 비율이 3.4%뿐이다. 맞힌 사진과 틀린 사진의 폐 안 비율은 비슷했다 (0.319 대 0.323).
- **가리기 시험:** 지도 점수가 높은 칸 40개(전체의 16%)를 가리면 예측 확률이 −0.537, 무작위 칸을 가려도 −0.559, 낮은 칸을 가리면 +0.005만 변했다 (가리는 값을 두 가지로 바꿔도 같은 경향). **지도가 '영향이 없는 곳'은 가려냈지만, 높은 칸이 무작위 칸보다 더 중요하다는 근거는 없다.** 모델이 사진 전체의 질감·통계 같은 넓은 단서에 기대고 있을 가능성과 맞지만, 이 시험으로 알 수는 없다.
- **그래서 '모델이 폐를 본다'고 말할 수 없다.** Grad-CAM은 '어디'만 알려 주고 그곳에서 '무엇'에 반응했는지(글자 표식, 어깨, 촬영 방식, 폐 소견 등)는 모른다. 시험 ①·②의 결론도 '이 기본 모델 계열'로 범위를 좁혀 읽어야 한다. 필터가 폐 소견이 아니라 가장자리·질감 단서를 건드렸을 가능성을 배제하지 못한다.

7 AWS 구성, 검산, 종료 기록

7.1 구성



보안 그룹은 내 공인 IP(/32)만 허용 · 역할은 인라인 최소 권한 (Lambda: 본인 Endpoint 호출, 웹: 본인 함수 호출)
Endpoint가 돌려주는 것은 확률 3개뿐이다 (Grad-CAM·설명문은 배포 경로에 없음).

그림 7. AWS 구성도. 서비스 경로는 10/23에 만들어 발표 시연에 쓰고 발표 직후 삭제했다. 학습 경로의 S3 모델과 기록은 남아 있다.

구성 요소	AWS 서비스	설정	상태
데이터·결과 저장	Amazon S3	원천 5,856장은 읽기 전용(`s3://aws-say3-dataset1/pneumonia-xray/chest_xray/`), 학생 경로 `s3://aws-say3-student-dataset/students/<학생ID>/P1/cxr/` 아래에 manifests·weights·code·experiments·lung512·deployment	**유지** (모델 포함)
모델 학습	SageMaker 학습 작업	PyTorch 2.2 GPU 컨테이너(py310). 초기 실험(A~D·P1~P4)은 ml.g4dn.xlarge, 512 이후는 ml.g4dn.2xlarge(vCPU 8, JPEG 디코딩이 병목), 최대 실행 5,400초	작업 완료
학습 (일부)	SageMaker JupyterLab	ml.g4dn.xlarge(T4), PyTorch 2.8. 기준 b 3개·증강 v 3개 (합 약 2.8시간)	앱 삭제됨
모델 추론	SageMaker Endpoint	ml.m5.large 1대(CPU), pytorch-inference 2.6 컨테이너(py312), 모델: 기준 B512 seed 42, 입력 512 (`inference.py` 와 배포용 `metadata.json` 은 따로 작성)	**삭제됨**
중계	AWS Lambda	Python 3.12, 256 MB, 제한 85초, 환경변수로 Endpoint 이름	**삭제됨**
화면	EC2 t3.small + Flask	15 GiB gp3. 포트 8000(사진 올리기), 8001(필터 체험: 필터 8종 × 강도를 골라 원본과 필터본의 확률 비교)	**삭제됨**
권한·보안	IAM, 보안 그룹	인라인 최소 권한 정책(Lambda: 본인 Endpoint 호출, 웹: 본인 함수 호출), 보안 그룹은 **내 공인 IP /32만** 허용(0.0.0.0/0 아님), 업로드 2 MiB 제한과 JPEG·PNG 형식 검증. 로그인이 없는 서비스라 보안 그룹이 유일한 접근 통제	보안 그룹 삭제됨, IAM 역할 2개·인스턴스 프로필 1개 남음 (7.5절)

7.2 예측 확률 검산

기획안의 재현성 목표(Q4)를 확인했다. 배포한 모델이 학습 결과 파일과 같은 파일이고, Endpoint가 돌려준 확률이 같은 모델을 내 컴퓨터에서 돌린 확률과 같은지 보았다.

비교	사진	결과
배포 가중치 대 학습 결과 `best_model.pt`	파일	sha256 동일 (`9182ff4bee4d3c0e…`) → 배포 모델 = B512 seed 42 (선택 에폭 18)
Endpoint 대 내 컴퓨터의 같은 모델 **(기획 Q4)**	val 20장	**예측 20/20 일치, 확률 최대 차이 7.5e-6** (기준 1e-4)
Endpoint 호출 (추가 확인)	val 29장	29/29 일치, 최대 차이 7.4e-6, 왕복 평균 0.30초
배포용 추론 코드를 로컬에서 실행 (추가 확인)	val 59장	59/59 일치, 최대 차이 7.1e-6
필터 체험 화면의 필터 경로 대 로컬 계산 (추가 확인)	필터 4종 × 약·강 × 예시	확률 최대 차이 2.7e-6
화면 → Lambda → Endpoint 전체 경로 **(기획 Q5)**	val 1장	**1.1초**, 세균성 0.9998 (내 컴퓨터의 같은 모델도 0.9998)

검산 스크립트는 `src/endpoint_verify.py` , `deploy/verify_local.py` 다. 실행 로그는 파일로 저장하지 않고 작업 기록에 숫자만 남겼고, Endpoint를 삭제해서 지금은 다시 돌릴 수 없다 (`deploy/endpoint_ctl.py` 등으로 다시 만들면 재현할 수 있다).

7.3 학습 작업과 청구 시간

43개의 학습 작업을 조회했고 청구 시간 합계는 **7.83시간**이다 (ml.g4dn.2xlarge 4.61시간, ml.g4dn.xlarge 3.23시간). 이와 별도로 JupyterLab에서 모델 6개를 약 2.83시간 학습했다. 시간당 단가는 확인하지 못해 금액으로 바꾸지 않았다. 과적합을 줄이는 실험(r, 15개)은 설계 방향이 test 결과에 영향받을 수 있다는 지적으로 **결과를 보지 않고 취소**했고, 약 1시간치가 청구되었다.

실험 묶음	인스턴스	청구(분)	실험 묶음	인스턴스	청구(분)
smoke (4개)	xlarge 4	16	p4 (1개)	xlarge 1	20
a (1개)	xlarge 1	22	testeval (2개)	xlarge 2	10
envcheck (1개)	xlarge 1	4	b448 (1개)	2xlarge 1	16
b (1개)	xlarge 1	22	b512 (3개)	2xlarge 3	54
d (3개)	xlarge 1, 2xlarge 2	47	shifteval (1개)	2xlarge 1	10
c (1개)	xlarge 1	22	r (과적합 줄이기, 취소) (15개)	2xlarge 15	67
p1 (1개)	xlarge 1	19	l (3개)	2xlarge 3	51
p2 (1개)	xlarge 1	20	lv (3개)	2xlarge 3	53
p3 (1개)	xlarge 1	19			

7.4 배포 때 알게 된 점

- 강의 예시 `inference.py` 는 입력 크기 224와 metadata.json의 `preprocess.resize / mean / std` 형식을 요구해서, 우리 모델(512)에 맞춰 두 곳을 고치고 배포용 metadata.json을 따로 만들었다 (학습 결과 파일은 건드리지 않음).
- Endpoint는 확률 3개만 돌려준다. Grad-CAM과 설명문은 배포 경로에 없다 (기획안의 Endpoint 설계와 다름).

7.5 종료 기록

발표 직후(10/23) 삭제를 실행하고, 읽기 전용 조회로 **10/23 18:06과 10/26 10:04에 두 번** 남은 자원을 확인했다. 아래는 최신 조회 결과다 (스크립트 `tools/aws_teardown_check.py`, 전문 `reports/aws_teardown_check_20261023.md`, `…20261026.md`). 가이드의 '콘솔 스크린샷' 대신 조회 기록을 남겼다.

자원	남은 개수	자원	남은 개수
SageMaker Endpoint	0	SageMaker Endpoint 구성	0
SageMaker 모델	0	SageMaker 노트북 인스턴스	0
Lambda 함수	0	EC2 인스턴스 (종료되지 않은 것)	0
EBS 볼륨	0	보안 그룹	0
키 페어	0	탄력적 IP	0
진행 중인 학습 작업	0		

- **남은 것 (비용은 거의 없음):** IAM 역할 `p1-cxr-<학생ID>-lambda` · `-web` 과 인스턴스 프로필 `-web` (인라인 정책만 있음)은 이 계정에 삭제 권한이 없어 지우지 못했다 → 필요하면 강사에게 삭제를 요청한다. S3의 배포용 모델 묶음 (`deployment/b512/model_with_code.tar.gz`, 42 MB)은 다시 배포할 때 쓰려고 남겼다.
- Endpoint와 EC2는 켜 두는 동안 과금되어 **배포 후 바로 지우는 계획**이었고 그대로 실행했다. 이 때문에 발표 때 쓴 접속 주소는 더 이상 열리지 않는다. 대신 코드·결과·보고서를 GitHub 저장소(`github.com/MuakTiger/p1-see-through-cxr`)에 올려 제출한다.

8 한계와 다음 단계

8.1 한계

1. **필터는 실제 장비가 아니다.** 장비 변수를 조절한 것이 아니라 결과를 흉내 낸 것이고, 강도는 임의로 정해서 필터끼리 점수 하락을 직접 비교할 수 없다. 제조사 후처리는 실제 알고리즘이 아닌 대표 기법이다. 8비트 JPEG라 톤 곡선을 모르고 관전압의 에너지 의존 대비를 만들지 못했다. 다른 병원의 실제 사진으로는 확인하지 못했다.

2. **데이터가 한 병원, 1~5세 소아 사진**이다. 성인·다른 병원에는 적용할 수 없고, 세균성/바이러스성 라벨의 확진 근거가 공개되지 않아 라벨 오류 가능성이 있다.
3. **반복 수가 적다.** 모델마다 seed 3개이고 표준편차는 거친 추정이다. val 점수가 가장 높은 에폭을 고르는 규칙이 흔들림을 키운다 (선택 에폭이 1인 모델이 있었다). 같은 설정에서도 test F1이 0.67~0.74로 흔들렸다.
4. **test는 여러 번 열렸다.** 224 모델 8개에 한 번씩, B512 계열은 모델마다 한 번씩 평가했고, 설계 때 B512의 test 결과를 알고 있었다. 사전 계획 문서와 해시, 결과를 보고 설계를 바꾸지 않은 점으로 완화했지만 '한 번도 안 본 test'는 아니다. test 정상 사진은 집단이 달라 절대 점수보다 변화량 중심으로 읽었다.
5. **test 점수가 낮은 원인은 모른다.** 저장 화질·가로 늘이기는 단독 원인이 아니었고, 구도(폐가 사진 세로를 채우는 정도)가 연관되지만 크롭 재학습으로 확인하지 못했다.
6. **폐 영역 모델은 두 단계 시스템**이다. 분할 오류가 그대로 전달되고(실패는 전부 세균성), 폐 마스크는 사진 12장만 눈으로 확인했으며, 폐 윤곽의 모양이 새 단서가 될 수 있다. 필터 시험의 마스크는 필터 없는 사진 기준이다.
7. **Grad-CAM은 '어디'만 알려 준다.** 가리기 시험에서 높은 칸과 무작위 칸의 영향이 비슷했다. 모델이 폐를 본다고 말할 수 없다.
8. **기획안의 일부를 하지 못했다.** 판단 보류 곡선, 보호자용 문장 틀과 이해도 평가, Grad-CAM·설명문이 들어간 배포, 시연 영상 파일, 콘솔 스크린샷.
9. **발표 때 쓴 접속 주소로는 확인할 수 없다.** 배포는 발표 때만 운영하고 지웠다. 코드·결과·보고서는 GitHub 저장소로 제출하고, 같은 화면은 코드(`deploy/`)로 다시 만들 수 있다 (예상 비용: Endpoint와 EC2를 켜 둔 시간만큼).

8.2 다음 단계

1. 다른 병원·다른 장비로 찍은 사진으로 확인한다 (이 보고서의 필터 시험이 실제 장비 차이를 얼마나 닮았는지 보는 것이 핵심).
2. 폐 상자로 자르거나 패딩 리사이즈로 구도를 맞춰 다시 학습한다 (강사 제안). 원인이 구도인지 확인하는 가장 직접적인 실험이다.
3. 증강의 평가는 학습에 쓰지 않은 종류의 변화로 해서 방어력을 따로 본다.
4. 판단 보류와 쉬운 설명문을 최종 모델에 연결하고 사람이 읽고 맞는지 평가한다.

부록 A 필터 33조건 전체 결과 (기준 모델 B512, seed 42)

val 1,030장, test 618장. 변화 = 같은 모델의 원본 점수 대비. *는 95% 구간(환자 묶음 bootstrap)이 0을 포함하지 않는 조건. 위쪽 8종이 본편 24조건, 아래 흐림·밝게·어둡게가 부록 9조건이다. 필터를 안 건 원본 점수는 val 0.843, test 0.670.

필터	단계	값	val F1	val 변화	95% 구간	test F1	test 변화	95% 구간
원본 (필터 없음)	-	-	**0.843**	-	-	**0.670**	-	-
관전류↓ (선량)	약	1/4	0.849	+0.006	[−0.003, +0.016]	0.658	−0.012	[−0.027, +0.001]
	중	1/16	0.830	−0.013	[−0.028, +0.002]	0.667	−0.003	[−0.023, +0.017]
	강	1/64	0.785	−0.058 *	[−0.081, −0.038]	0.624	−0.046 *	[−0.078, −0.017]
노출시간 ↑	약	2	0.831	−0.012	[−0.025, +0.002]	0.595	−0.076 *	[−0.103, −0.051]
	중	4	0.792	−0.051 *	[−0.070, −0.032]	0.511	−0.159 *	[−0.196, −0.126]
	강	8	0.707	−0.136 *	[−0.165, −0.110]	0.442	−0.228 *	[−0.267, −0.190]
산란	약	0.25	0.827	−0.016 *	[−0.030, −0.003]	0.646	−0.024 *	[−0.045, −0.005]
	중	0.5	0.812	−0.031 *	[−0.052, −0.012]	0.628	−0.043 *	[−0.068, −0.016]
	강	1.0	0.763	−0.080 *	[−0.106, −0.055]	0.568	−0.102 *	[−0.134, −0.069]
관전압 ↑	약	(0.85, 0.8)	0.812	−0.031 *	[−0.048, −0.014]	0.605	−0.065 *	[−0.091, −0.038]
	중	(0.70, 0.6)	0.732	−0.111 *	[−0.139, −0.084]	0.508	−0.162 *	[−0.198, −0.127]
	강	(0.60, 0.5)	0.625	−0.218 *	[−0.252, −0.186]	0.452	−0.218 *	[−0.258, −0.181]
센서 해상도	약	0.5	0.842	−0.001	[−0.013, +0.010]	0.692	+0.022 *	[+0.004, +0.041]
	중	1.0	0.816	−0.027 *	[−0.045, −0.010]	0.642	−0.028 *	[−0.055, −0.002]
	강	2.0	0.750	−0.093 *	[−0.121, −0.066]	0.503	−0.167 *	[−0.204, −0.129]
경계 강조	약	0.5	0.840	−0.003	[−0.015, +0.011]	0.703	+0.033 *	[+0.015, +0.052]
	중	1.0	0.835	−0.008	[−0.023, +0.007]	0.700	+0.030 *	[+0.008, +0.056]
	강	2.0	0.788	−0.055 *	[−0.078, −0.035]	0.674	+0.004	[−0.032, +0.038]
대비 보정	약	CLAHE 1.5	0.829	−0.015	[−0.032, +0.002]	0.624	−0.046 *	[−0.076, −0.016]
	중	CLAHE 3.0	0.781	−0.062 *	[−0.086, −0.037]	0.539	−0.131 *	[−0.171, −0.092]
	강	HE	0.809	−0.034 *	[−0.053, −0.014]	0.616	−0.055 *	[−0.088, −0.021]
JPEG 압축	약	75	0.828	−0.015 *	[−0.030, −0.001]	0.667	−0.003	[−0.022, +0.016]
	중	40	0.811	−0.032 *	[−0.050, −0.015]	0.648	−0.022	[−0.053, +0.005]
	강	20	0.791	−0.051 *	[−0.072, −0.031]	0.579	−0.091 *	[−0.129, −0.059]
흐림	약	0.5	0.815	−0.028 *	[−0.045, −0.010]	0.652	−0.018	[−0.046, +0.008]
	중	1.0	0.766	−0.076 *	[−0.104, −0.051]	0.522	−0.148 *	[−0.187, −0.111]
	강	2.0	0.380	−0.463 *	[−0.498, −0.429]	0.345	−0.325 *	[−0.369, −0.284]
밝게	약	0.85	0.840	−0.003	[−0.012, +0.005]	0.670	−0.000	[−0.012, +0.011]
	중	0.7	0.836	−0.007	[−0.018, +0.004]	0.664	−0.006	[−0.024, +0.011]
	강	0.55	0.821	−0.022 *	[−0.036, −0.008]	0.652	−0.018	[−0.043, +0.004]
어둡게	약	1.2	0.843	−0.001	[−0.011, +0.011]	0.668	−0.002	[−0.017, +0.013]
	중	1.45	0.844	+0.001	[−0.013, +0.014]	0.668	−0.002	[−0.020, +0.016]
	강	1.8	0.835	−0.008	[−0.025, +0.010]	0.669	−0.001	[−0.027, +0.024]

부록 B 초기 실험 (입력 224)

10/16~10/19에 입력 224로 학습한 8개 모델이다 (seed 42, ml.g4dn.xlarge). 실험 D가 평가 계획이 지정한 최종 모델이었고, 이후 기준을 B512로 옮겼다 (2.4절).

실험	바꾼 것 (입력 224, seed 42)	val F1	test F1 [95% 구간]	정상 recall (val / test)	바이러스성 recall (val / test)
A	layer4도 얼림, fc만 학습	0.806	0.748 [0.706, 0.787]	0.955 / 0.610	0.551 / 0.707
B	기준: layer4 미세조정, 증강·전처리 없음	0.818	0.719 [0.677, 0.757]	0.974 / 0.498	0.616 / 0.741
C	B + 클래스 가중치 손실	0.821	0.690 [0.648, 0.727]	0.966 / 0.481	0.649 / 0.680
D	B + 노이즈 증강 (학습 사진 50%, std 0~10)	0.834	0.692 [0.652, 0.732]	0.981 / 0.442	0.696 / 0.762
P1	B + 히스토그램 평활화 전처리	0.822	0.700 [0.659, 0.739]	0.974 / 0.455	0.674 / 0.789
P2	B + CLAHE 전처리	0.831	0.684 [0.642, 0.722]	0.955 / 0.433	0.750 / 0.782
P3	B + 가우시안 블러(σ1.5) 전처리	0.818	0.733 [0.692, 0.770]	0.977 / 0.567	0.707 / 0.741
P4	B + 언샤프 마스킹 전처리	0.829	0.757 [0.716, 0.793]	0.989 / 0.632	0.667 / 0.721

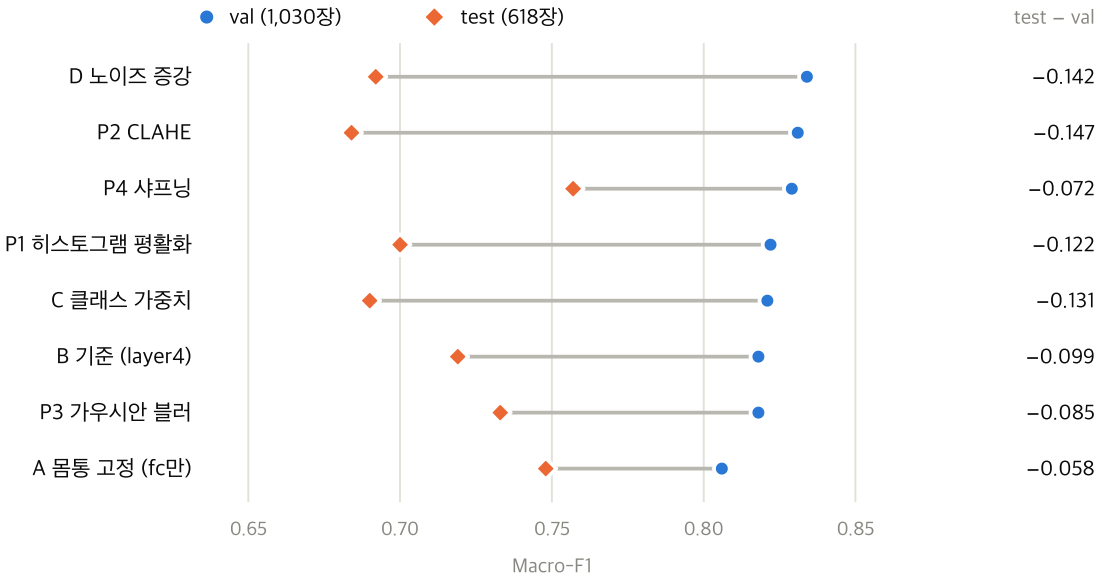


그림 8. 초기 실험 8개의 val 점수와 test 점수. 모든 모델이 test에서 낮고(−0.058~−0.147) val 순위가 test 순위와 달랐다 (순위상관 −0.50). 전처리·증강·클래스 가중치 중 어느 것도 이 낙폭을 없애지 못했다.

B와 D의 test 점수는 구간이 겹쳐(B 0.719 [0.677, 0.757], D 0.692 [0.652, 0.732]) 차이를 말할 수 없다. D를 seed 3개로 다시 학습한 원본 val 점수는 0.834 / 0.818 / 0.818로, 노이즈 증강의 원본 점수 개선은 seed 흔들림 안쪽이었고 노이즈 약점 보완(std 16에서 F1 0.363 → 0.747~0.774)만 3개 seed에서 재현되었다. 입력 448 모델(B448)은 흐림에 더 약했다(흐림 3단계 평균 F1 0.585, B는 0.738). 전처리 4종(P1~P4)은 원본 점수가 흔들림 수준이었고 필터마다 강한 곳·약한 곳이 달랐다: CLAHE는 바이러스성 recall이 가장 높았지만 노이즈에 가장 약했고(노이즈 16에서 0.148), 블러는 노이즈·흐림에 강했다.

부록 C 가이드 필수 제출물 대응표

가이드 필수 제출	이 프로젝트의 산출물	패키지 안 위치
분할	manifest.csv · split_manifest.csv · split_summary.csv, 분할 규칙·점검 보고서	`manifests/`
학습 이력	실험별 history.csv, config.json, experiment_summary.json (모델 26개)	`results/<실험>/`
평가 CSV	val 예측 val_predictions.csv, 필터 시험 shift_results.csv(모델 15개 × val·test), 224 모델 test_predictions.csv·metrics.csv	`results/`, `reports/equipment_v2/`, `reports/test_eval/aws/`
S3 모델 주소	부록 D의 표 + 작업 제출 기록(작업 이름·입력·출력·해시)	`aws/submissions/`
AWS 구성	7.1절, 배포 스크립트와 웹 화면 코드	`deploy/`
시연	발표 중 실시간 시연 (화면 캡처는 발표자료 12쪽). 시연 영상 파일 없음	발표자료
(추가) 소스코드·결과물 링크	GitHub 저장소 (첫 화면에 결과 그림과 보고서 링크)	저장소 첫 화면(README)
종료 기록	조회 기록 2회(10/23, 10/26) + 스크립트 (콘솔 스크린샷 없음)	`aws/aws_teardown_check_*.md`
(추가) 전처리 비교	P0~P4 갤러리·통계·비교표	`reports/preprocess/`
(추가) 보호자 설명	규칙 기반 설명문 코드와 예시 (보호자용 4단 문장 틀·이해도 평가는 미완)	`src/explain.py`, `reports/explain/`

부록 D 모델 S3 주소

AWS 학습 작업 모델은 `experiments/<작업 이름>/output/model.tar.gz` 이고, 작업 이름은 `p1-cxr-<학생ID>-` 뒤에 표의 이름과 시각이 붙는다. JupyterLab 모델은 결과 묶음 `experiments/aug_runs/results_<이름>.tgz` 다 (S3에서 존재를 확인함).

모델	학습	모델 주소 (S3, 학생 경로 `s3://aws-say3-student-dataset/students/<학생ID>/P1/cxr/` 아래)	선택 에폭	val F1
기준 B512 (seed 42)	학습 작업	`p1-cxr-<학생ID>-b512-20261022-111844/output/model.tar.gz`	18	0.843
기준 B512 (seed 43)	학습 작업	`p1-cxr-<학생ID>-b512-s43-20261022-190104/output/model.tar.gz`	28	0.844
기준 B512 (seed 44)	학습 작업	`p1-cxr-<학생ID>-b512-s44-20261022-190105/output/model.tar.gz`	18	0.832
폐 영역 l (seed 42)	학습 작업	`p1-cxr-<학생ID>-l-s42-20261022-190058/output/model.tar.gz`	29	0.832
폐 영역 l (seed 43)	학습 작업	`p1-cxr-<학생ID>-l-s43-20261022-190100/output/model.tar.gz`	21	0.820
폐 영역 l (seed 44)	학습 작업	`p1-cxr-<학생ID>-l-s44-20261022-190102/output/model.tar.gz`	25	0.827
폐 영역 + 증강 lv (seed 42)	학습 작업	`p1-cxr-<학생ID>-lv-s42-20261022-191511/output/model.tar.gz`	19	0.821
폐 영역 + 증강 lv (seed 43)	학습 작업	`p1-cxr-<학생ID>-lv-s43-20261022-191513/output/model.tar.gz`	14	0.812
폐 영역 + 증강 lv (seed 44)	학습 작업	`p1-cxr-<학생ID>-lv-s44-20261022-191515/output/model.tar.gz`	30	0.818
기준 b (seed 42)	JupyterLab	`aug_runs/results_b-s42.tgz`	17	0.836
기준 b (seed 43)	JupyterLab	`aug_runs/results_b-s43.tgz`	1	0.831
기준 b (seed 44)	JupyterLab	`aug_runs/results_b-s44.tgz`	19	0.842
증강 v (seed 42)	JupyterLab	`aug_runs/results_v-s42.tgz`	27	0.835
증강 v (seed 43)	JupyterLab	`aug_runs/results_v-s43.tgz`	25	0.832
증강 v (seed 44)	JupyterLab	`aug_runs/results_v-s44.tgz`	5	0.827
초기 A (224, seed 42)	학습 작업	`p1-cxr-<학생ID>-a-20261019-101748/output/model.tar.gz`	10	0.806
초기 B (224, seed 42)	학습 작업	`p1-cxr-<학생ID>-b-20261019-103853/output/model.tar.gz`	21	0.818

모델	학습	모델 주소 (S3, 학생 경로 `s3://aws-say3-student-dataset/students/<학생ID>/P1/cxr/` 아래)	선택 에폭	val F1
초기 C (224, seed 42)	학습 작업	`p1-cxr-<학생ID>-c-20261019-143150/output/model.tar.gz`	30	0.821
초기 D (224, seed 42)	학습 작업	`p1-cxr-<학생ID>-d-20261019-134621/output/model.tar.gz`	26	0.834
초기 D (224, seed 43)	학습 작업	`p1-cxr-<학생ID>-d-s43-20261021-143018/output/model.tar.gz`	7	0.818
초기 D (224, seed 44)	학습 작업	`p1-cxr-<학생ID>-d-s44-20261021-143019/output/model.tar.gz`	20	0.818
초기 P1 HE (224)	학습 작업	`p1-cxr-<학생ID>-p1-20261019-153257/output/model.tar.gz`	10	0.822
초기 P2 CLAHE (224)	학습 작업	`p1-cxr-<학생ID>-p2-20261019-153259/output/model.tar.gz`	19	0.831
초기 P3 블러 (224)	학습 작업	`p1-cxr-<학생ID>-p3-20261019-153301/output/model.tar.gz`	16	0.818
초기 P4 샤프닝 (224)	학습 작업	`p1-cxr-<학생ID>-p4-20261019-153303/output/model.tar.gz`	26	0.829
B448 (입력 448)	학습 작업	`p1-cxr-<학생ID>-b448-20261020-161517/output/model.tar.gz`	12	0.830

부록 E 제출 패키지 구성과 재현 방법

위치	내용
`README.md`	무엇이 어디에 있는지, 재현 방법, 제외한 것
`manifests/`	목록표와 최종 분할 (5,856장, sha256, 환자 그룹, split)
`training/`	학습·평가 코드: train.py(기준), train_aug.py(장비 효과 증강), train_lung.py(폐 영역), equipment_direct.py(필터 5종), shift_filters.py, evaluate.py 등
`src/`	분석·평가·그림 스크립트 (필터 시험 equipment_eval_direct.py, 요약 lung_summary.py, 점검 gradcam_b512_checks.py 등)
`submit_*.py`	SageMaker 작업 제출 스크립트
`deploy/`	Endpoint·Lambda·EC2 생성·삭제 스크립트와 웹 화면(Flask) 코드. 모델 가중치와 개인키는 제외
`app/`	224 모델 D용 Streamlit 시연 화면 (초기 버전)
`results/`	실험별 학습 기록 (모델 가중치 제외)
`reports/`	실험 보고서·표·그림, 평가 계획 문서와 해시 파일
`aws/`	작업 제출 기록, 종료 기록
`tools/`	이 보고서를 만드는 코드 (`tools/final_report/`), 종료 기록 스크립트

```
# 1) 환경 (Python 3.11): pip install -r requirements.txt   # AWS 접근은 aws_config.json(제출물에 없음)에 프로필·역할·버킷을 채워서 쓴다
# 2) 학습 (SageMaker 학습 작업): 기준 모델 B512, seed 42
python submit_training.py --experiment-id b512 --extra train-mode=layer4 --extra input-size=512 --num-workers 8 --instance-type ml.g4dn.2xlarge
# 3) 필터 시험 (모델 가중치는 제출물에 없다: S3의 model.tar.gz(부록 D)를 풀어 results/<실험>/model/ 에 둔다. test는 계획 문서 해시가 맞을 때만 열림)
python src/equipment_eval_direct.py --model-dir results/b512-20261022-111844/model --split val --device cpu
# 4) 요약표와 판정
python src/lung_summary.py ;  python src/vaccine_summary.py
# 5) 이 보고서 다시 만들기
python tools/final_report/build.py
```

제외한 것: AWS 접근 정보(aws_config.json 등), 개인키, 가상환경, 모델 가중치(.pt, 용량이 크고 S3에 있음), 원본 영상(공개 데이터, 약 1.2 GB, 출처와 목록표 sha256으로 대신), 다른 프로젝트 폴더. 학생 ID는 `<학생ID>` 로, 12자리 계정 번호는 `<ACCOUNT>` 로 가렸다.

부록 F 용어

용어	뜻
Macro-F1	정상·세균성·바이러스성 세 클래스의 F1 점수를 단순 평균한 값. 클래스 수가 달라도 고르게 맞히는지 본다.
recall (민감도)	그 병인 사진 중 맞힌 비율. 정상 recall = 정상 사진을 정상이라고 맞힌 비율.
AUROC	확률의 순서만으로 두 클래스를 얼마나 잘 가르는지 (0.5는 무작위, 1.0은 완벽).
val / test	val은 모델을 고르고 개발하는 데 쓴 사진(1,030장), test는 마지막에 확인하는 사진(618장).
seed	학습 때의 난수를 정하는 숫자. 데이터 분할은 그대로 두고 초기화·순서·증강의 우연만 바꾼다. 3개 평균 ± 표준편차로 흔들림을 본다.
필터 약·중·강	같은 장비 효과를 3단계 세기로 건 시험 조건. '강'이 가장 센 단계.
연습에서 본 필터 / 못 본 필터	장비 효과 증강 때 학습에 섞은 필터 5종(관전압·관전류·노출시간·산란·센서)과, 학습에 쓰지 않은 3종(경계 강조·대비 보정·JPEG).
장비 효과 증강	학습 사진의 50%에 장비 필터 5종 중 하나를 무작위 세기로 거는 데이터 증강.
'차이 있음' 판정	두 묶음의 평균 차이가 기준 묶음 표준편차(seed 3개)의 2배 이상일 때. 아니면 '말할 수 없음'.
Grad-CAM	모델이 판단할 때 사진의 어느 부분에 반응했는지를 색으로 보여 주는 지도. 어디만 알려 주고 무엇에 반응했는지는 모른다.

참고문헌: [1] Kermany et al., 2018, Cell 172(5). [2] Zech et al., 2018, PLOS Medicine 15(11). [3] Selvaraju et al., 2017, Grad-CAM, ICCV. [4] He et al., 2016, ResNet, CVPR. [5] Cohen et al., 2022, TorchXRayVision, MIDL. [6] Zuiderveld, 1994, CLAHE, Graphics Gems IV.